




HERRAMIENTAS DE SOFTWARE PARA BIG DATA

HERRAMIENTAS DE ETL - 05



COMPONENTES DE UN DATALAKE

¿QUÉ SIGNIFICA ETL?



ETL SIGNIFICA "EXTRACT, TRANSFORM, LOAD" (EXTRACCIÓN, TRANSFORMACIÓN Y CARGA, EN ESPAÑOL).

ES UN PROCESO UTILIZADO EN EL ÁMBITO DE LA GESTIÓN Y ANÁLISIS DE DATOS PARA MOVER Y TRANSFORMAR DATOS DESDE MÚLTIPLES FUENTES HACIA UN SISTEMA DE ALMACENAMIENTO CENTRALIZADO, COMO PUEDE SER UNA BASE DE DATOS, UN DATA WAREHOUSE O UN DATALAKE.

SI EL SISTEMA ESTÁ DISTRIBUIDO, COMO LO ESTÁ EL DATALAKE O PUEDE ESTARLO UN DATAWAREHOUSE O BASE DE DATOS, ES EN APARIENCIA CENTRALIZADO, PORQUE FÍSICAMENTE ESTÁ EN VARIOS SERVIDORES.

EL PROCESO ETL CONSTA DE TRES FASES.

EXTRACCIÓN




EN ESTA ETAPA, LOS DATOS SE EXTRAEN DE DIVERSAS FUENTES, QUE PUEDEN SER BASES DE DATOS, ARCHIVOS DE TEXTO PLANOS, SERVICIOS WEB, APIS U OTRAS FUENTES DE DATOS.

LOS DATOS EXTRAÍDOS SUELEN SER DATOS BRUTOS O SEMIESTRUCTURADOS EN SU FORMA ORIGINAL.

TAMBIÉN PUEDEN SER DATOS NO ESTRUCTURADOS COMO AUDIOS, FOTOS, VIDEOS, ENTRE OTROS.

TRANSFORMACIÓN

Data Transformation




DESPUÉS DE LA EXTRACCIÓN, LOS DATOS SE SOMETEN A PROCESOS DE TRANSFORMACIÓN.

DURANTE ESTA ETAPA, LOS DATOS SE LIMPIAN, SE AJUSTAN Y SE REESTRUCTURAN SEGÚN LAS NECESIDADES ESPECÍFICAS DEL ANÁLISIS O DEL SISTEMA DE DESTINO.

LAS TRANSFORMACIONES PUEDEN INCLUIR

- FILTRADO
- LIMPIEZA DE DATOS INCORRECTOS O INCOMPLETOS
- CONVERSIÓN DE FORMATOS
- CÁLCULOS Y AGREGACIONES.


CARGA



UNA VEZ QUE LOS DATOS HAN SIDO EXTRAÍDOS Y TRANSFORMADOS, SE CARGAN EN EL SISTEMA DE DESTINO, QUE SUELE SER UNA BASE DE DATOS, UN DATA WAREHOUSE O UN DATALAKE.

DEPENDIENDO DE LA FRECUENCIA DEL PROCESO ETL, LOS DATOS PUEDEN CARGARSE EN LOTES PERIÓDICOS (PROCESAMIENTO EN BATCHES) O EN TIEMPO REAL (STREAMING).

¿SIEMPRE ES EN ESE ORDEN?



NO NECESARIAMENTE TENEMOS QUE CUMPLIR EL ÓRDEN DE EXTRAER TRANSFORMAR Y CARGAR.


SIEMPRE SE TIENEN QUE EXTRAER LOS DATOS DE SU FUENTE ORIGINAL.

PERO EL MOMENTO DE TRANSFORMARLOS PUEDE SER ANTES O DESPUÉS DE CARGAR LOS DATOS. ESTO DEPENDE DE DÓNDE ESTAMOS TRABAJANDO.

SI QUEREMOS INGESTAR LOS DATOS A UN SISTEMA QUE CENTRALIZA ÚNICAMENTE DATOS ESTRUCTURADOS, NORMALMENTE VAMOS A REALIZAR TODAS LAS TRANSFORMACIONES ANTES DE LA CARGA.

ESTO ES ALGO QUE APORTA POCA FLEXIBILIDAD.

¿SIEMPRE ES EN ESE ORDEN?




EN CASO DE PASAR INFORMACIÓN A UN REPOSITORIO DE DATOS QUE NO REQUIERE ESTRUCTURAR DATOS PREVIAMENTE, PUEDE HACERSE LA TRANSFORMACIÓN LUEGO CON LA MISMA HERRAMIENTA DE ETL U OTRA HERRAMIENTA DISTINTA.

ESTE ES EL CASO DE UN DATALAKE.

SI TENEMOS LOS DATOS EN UN REPOSITORIO EN APARIENCIA CENTRALIZADO, COMO UN DATALAKE, DISPONEMOS DE HERRAMIENTAS MUCHO MÁS EFICIENTES PARA REALIZAR TRANSFORMACIONES, AGREGACIONES Y CRUZAMIENTO DE DATOS, QUE LAS HERRAMIENTAS DE ETL DISPONIBLES.

POR LO TANTO, LAS TRANSFORMACIONES QUE SE PUEDEN REALIZAR PUEDEN SER CON PROPÓSITOS DE CONTROL, O SOBRE LA METADATA, MÁS QUE PARA ENRIQUECER DATOS O REALIZAR CÁLCULOS.

¿QUÉ TIPOS DE TRANSFORMACIÓN SON POSIBLES?



FILTRADO DE DATOS:

SE ELIMINAN FILAS DE DATOS QUE NO CUMPLEN CON CIERTOS CRITERIOS O CONDICIONES ESPECÍFICAS.

POR EJEMPLO, SE PUEDEN FILTRAR REGISTROS CON FECHAS FUTURAS O VALORES NULOS.

EN GENERAL FILTRAREMOS DATOS QUE TENGAN ERRORES O NO ESPERAMOS SACAR VALOR AHORA O EN UN FUTURO CERCANO.


ELIMINACIÓN DE DUPLICADOS:

SE IDENTIFICAN Y ELIMINAN REGISTROS DUPLICADOS EN FUNCIÓN DE UNA O VARIAS COLUMNAS CLAVE.

ESTO GARANTIZA LA INTEGRIDAD DE LOS DATOS Y EVITA PROBLEMAS EN EL ANÁLISIS.

¿QUÉ TIPOS DE TRANSFORMACIÓN SON POSIBLES?

Data Transformation



NORMALIZACIÓN DE DATOS:

SE AJUSTAN LOS DATOS A UN FORMATO ESTÁNDAR.

POR EJEMPLO, SE PUEDEN CONVERTIR TODAS LAS DIRECCIONES A MAYÚSCULAS O ESTANDARIZAR FECHAS EN UN FORMATO ESPECÍFICO.


CONCATENACIÓN DE COLUMNAS:

SE COMBINAN DOS O MÁS COLUMNAS EN UNA SOLA.

ESTO PUEDE SER ÚTIL PARA CREAR CLAVES COMPUESTAS O GENERAR VALORES CALCULADOS.

¿QUÉ TIPOS DE TRANSFORMACIÓN SON POSIBLES?

Data Transformation



DIVISIÓN DE COLUMNAS:

SE DIVIDE UNA COLUMNA EN MÚLTIPLES COLUMNAS.

ESTO ES ÚTIL CUANDO SE TIENE UNA COLUMNA QUE CONTIENE INFORMACIÓN COMBINADA QUE DEBE DESGLOSARSE.


CONVERSIÓN DE TIPOS DE DATOS:

SE CAMBIAN LOS TIPOS DE DATOS DE UNA COLUMNA PARA QUE SEAN COMPATIBLES CON EL DESTINO.

POR EJEMPLO, CONVERTIR UNA CADENA DE TEXTO QUE REPRESENTA UNA FECHA EN UN TIPO DE DATO DE FECHA.

¿QUÉ TIPOS DE TRANSFORMACIÓN SON POSIBLES?

Data Transformation



ENRIQUECIMIENTO DE DATOS:


SE AGREGAN DATOS ADICIONALES A PARTIR DE FUENTES EXTERNAS PARA ENRIQUECER LA INFORMACIÓN EXISTENTE. POR EJEMPLO, AGREGAR DATOS DEMOGRÁFICOS A PARTIR DE CÓDIGOS POSTALES.

CÁLCULOS Y AGREGACIONES:

SE REALIZAN OPERACIONES MATEMÁTICAS, COMO SUMAS, PROMEDIOS O CONTEOS, EN COLUMNAS NUMÉRICAS.

ESTO ES ESENCIAL PARA GENERAR MÉTRICAS Y RESÚMENES.

¿QUÉ TIPOS DE TRANSFORMACIÓN SON POSIBLES?



MAPEO DE VALORES:

SE REEMPLAZAN VALORES EXISTENTES POR OTROS SEGÚN UN MAPEO PREDEFINIDO.

POR EJEMPLO, CONVERTIR CÓDIGOS DE PRODUCTO EN NOMBRES DE PRODUCTOS.

DERIVACIÓN DE NUEVAS COLUMNAS:


SE CREAN NUEVAS COLUMNAS CALCULADAS A PARTIR DE DATOS EXISTENTES.

POR EJEMPLO, CALCULAR LA EDAD A PARTIR DE LA FECHA DE NACIMIENTO.

LIMPIEZA DE DATOS INCONSISTENTES:

SE CORRIGEN DATOS CON ERRORES TIPOGRÁFICOS, VALORES ATÍPICOS O FORMATOS INCORRECTOS.

¿POR QUÉ HACEMOS PROCESOS DE ETL?




CENTRALIZACIÓN Y ALMACENAMIENTO EFICIENTE:

LOS DATOS ESTÁN PRESENTES EN DIVERSAS FUENTES, JUNTARLOS EN UN SISTEMA DE ALMACENAMIENTO CENTRALIZADO, COMO UN DATAWAREHOUSE O UN DATA LAKE, FACILITA EL ACCESO Y LA ADMINISTRACIÓN DE LA INFORMACIÓN EN UN SOLO LUGAR PARA SER ALMACENADA Y RESPALDADA.

ANÁLISIS Y TOMA DE DECISIONES:

MOVERLOS A UN LUGAR CENTRALIZADO TAMBIÉN PERMITE REALIZAR ANÁLISIS MÁS EFECTIVOS Y TOMAR DECISIONES INFORMADAS BASADAS EN UNA VISIÓN COMPLETA DE LA INFORMACIÓN.

¿POR QUÉ HACEMOS PROCESOS DE ETL?




INTEGRACIÓN DE DATOS:

SE REFIERE AL PROCESO DE COMBINAR DATOS DE DIVERSAS FUENTES Y FORMATOS EN UNA SOLA VISTA COHERENTE Y UNIFICADA.

LOS DATOS DE VARIOS SISTEMAS SE TOMAN PARA HACER UN MODELO DE DATOS NUEVO.

¿POR QUÉ HACEMOS PROCESOS DE ETL?



INTEGRACIÓN DE SISTEMAS:


ALGUNAS ORGANIZACIONES TIENEN SISTEMAS AISLADOS QUE NO SE COMUNICAN ENTRE SÍ.

MOVER DATOS ENTRE ESTOS SISTEMAS PERMITE UNA MEJOR INTEGRACIÓN Y AUTOMATIZACIÓN DE PROCESOS.

CUMPLIMIENTO NORMATIVO:

EN ALGUNOS CASOS, ES NECESARIO MOVER DATOS PARA CUMPLIR CON REGULACIONES Y LEYES QUE REQUIEREN LA RETENCIÓN O ELIMINACIÓN ADECUADA DE INFORMACIÓN.


¿POR QUÉ NO HACEMOS ANALÍTICA DIRECTO CONTRA LAS FUENTES DE DATOS?



LOS MODELOS ANALÍTICOS COMO LOS QUE ARMAMOS EN UN DATAWAREHOUSE O DATALAKE SON MODELOS QUE ESTÁN OPTIMIZADOS PARA UNA LECTURA RÁPIDA, SACRIFICANDO LA ESCRITURA DE DATOS.

POR ESTE MOTIVO ES RECOMENDABLE HACER LOS PROCESOS DE ETL QUE ESCRIBEN GRANDES VOLUMENES DE DATOS, EN HORAS DE BAJA DEMANDA, DONDE NO SE ESTÉN REALIZANDO CONSULTAS. Y NO REALIZAR LA EXTRACCIÓN DIRECTAMENTE DESDE LA FUENTE DE DATOS, SINO DESDE UNA COPIA DE LA FUENTE O DE LAS ÚLTIMAS ACTUALIZACIONES DESDE LA ÚLTIMA EXTRACCIÓN. DISPONIBILIZADA EN OTRO LUGAR. POR EJEMPLO, EN UN SERVIDOR SFTP.


OLTP VS OLAP



NOS ENFRENTAMOS A DOS MODELOS DIFERENTES A LA HORA DE GESTIONAR SISTEMAS DE DATOS.

OLAP (PROCESAMIENTO ANALÍTICO EN LÍNEA) Y OLTP (PROCESAMIENTO DE TRANSACCIONES EN LÍNEA) SON DOS ENFOQUES CLAVE EN LA GESTIÓN DE BASES DE DATOS QUE SE UTILIZAN PARA DIFERENTES TIPOS DE APLICACIONES Y REQUERIMIENTOS.

OLTP



OLTP SE ENFOCA EN LA GESTIÓN DE TRANSACCIONES Y OPERACIONES DIARIAS DE UNA ORGANIZACIÓN.


SU OBJETIVO PRINCIPAL ES ADMITIR PROCESOS EMPRESARIALES COMO VENTAS, COMPRAS Y RESERVAS EN TIEMPO REAL.

LAS OPERACIONES OLTP SON PRINCIPALMENTE DE ESCRITURA Y LECTURA.

LOS USUARIOS REALIZAN TRANSACCIONES QUE ACTUALIZAN Y CONSULTAN DATOS CONSTANTEMENTE.

LA INTEGRIDAD DE LOS DATOS Y LA CONSISTENCIA SON CRÍTICAS.

OLTP




OLTP UTILIZA UN MODELO DE DATOS RELACIONAL, DONDE LOS DATOS SE ORGANIZAN EN TABLAS NORMALIZADAS PARA GARANTIZAR LA INTEGRIDAD Y LA CONSISTENCIA DE LOS DATOS.

LOS SISTEMAS OLTP ESTÁN OPTIMIZADOS PARA LA VELOCIDAD DE RESPUESTA Y LA CONCURRENCIA.

SE CENTRAN EN MANTENER LA INTEGRIDAD DE LOS DATOS Y ADMINISTRAR TRANSACCIONES CONCURRENTES.


OLAP



OLAP SE CENTRA EN EL ANÁLISIS DE DATOS Y LA GENERACIÓN DE INFORMES. SU OBJETIVO PRINCIPAL ES PROPORCIONAR A LOS USUARIOS LA CAPACIDAD DE CONSULTAR GRANDES CONJUNTOS DE DATOS PARA OBTENER INFORMACIÓN Y TOMAR DECISIONES ESTRATÉGICAS.

LAS OPERACIONES OLAP SON PRINCIPALMENTE DE LECTURA. LOS USUARIOS REALIZAN CONSULTAS COMPLEJAS PARA RESUMIR, AGRUPAR, FILTRAR Y ANALIZAR DATOS. LAS ACTUALIZACIONES DE DATOS EN SISTEMAS OLAP SUELEN SER MÍNIMAS Y PLANIFICADAS, COMO LA CARGA DE DATOS PERIÓDICA.

OLAP



OLAP UTILIZA UN MODELO DE DATOS MULTIDIMENSIONAL, DONDE LOS DATOS SE ORGANIZAN EN CUBOS O ESTRUCTURAS SIMILARES QUE REPRESENTAN DIMENSIONES Y MEDIDAS.


ESTO FACILITA LAS CONSULTAS Y EL ANÁLISIS DE DATOS.

LOS SISTEMAS OLAP ESTÁN OPTIMIZADOS PARA CONSULTAS Y ANÁLISIS DE ALTO RENDIMIENTO.

SUELEN UTILIZAR AGREGACIONES Y PRE-CÁLCULOS PARA ACELERAR LAS CONSULTAS COMPLEJAS.

PODEMOS A PARTIR DE NUESTROS ARCHIVOS CREAR NUEVOS PARA TENER MODELOS DE DATOS MULTIDIMENSIONALES EN EL DATALAKE.

HERRAMIENTAS DE ETL




EXISTE UNA VARIEDAD MUY GRANDE DE HERRAMIENTAS PARA REALIZAR TAREAS DE ETL.

ALGUNAS SON OPEN SOURCE, Y OTRAS SON ÚNICAMENTE DE PROVEEDORES CLOUD.

DENTRO DE LAS OPEN SOURCE, MUCHAS NACIERON CON EL ENFOQUE EN ANALYTICS PARA DATA WAREHOUSES TRADICIONALES Y MÁS TARDE SE ADAPTARON AL MUNDO DE BIG DATA.

MUCHAS DE ELLAS ESTÁN TAMBIÉN DENTRO DE SUITES DE PRODUCTOS QUE TIENEN MÁS FUNCIONALIDADES ADEMÁS DE SER UNA HERRAMIENTA DE ETL.

HERRAMIENTAS DE ETL



PODEMOS ENCONTRAR COMO EJEMPLO:

- PENTAHO
- TALEND
- GLUE
- CLOUD DATA FUSION
- AZURE DATA FACTORY
- **NIFI**

HERRAMIENTAS DE ETL (PENTAHO)



PENTAHO ES UNA PLATAFORMA DE INTELIGENCIA EMPRESARIAL DE CÓDIGO ABIERTO QUE OFRECE UNA SUITE COMPLETA DE HERRAMIENTAS PARA AYUDAR EN LA GESTIÓN, ANÁLISIS Y VISUALIZACIÓN DE DATOS.

FUE DESARROLLADA ORIGINALMENTE POR PENTAHO CORPORATION Y LUEGO ADQUIRIDA POR HITACHI DATA SYSTEMS EN 2015.

LA SUITE PENTAHO INCLUYE VARIAS HERRAMIENTAS QUE ABARCAN DIFERENTES ASPECTOS DEL PROCESAMIENTO DE DATOS Y LA INTELIGENCIA EMPRESARIAL.

HERRAMIENTAS DE ETL (PENTAHO)



PENTAHO DATA INTEGRATION (PDI): TAMBIÉN CONOCIDO COMO KETTLE, ES UNA HERRAMIENTA ETL QUE PERMITE EXTRAER, TRANSFORMAR Y CARGAR DATOS DESDE DIVERSAS FUENTES HACIA DESTINOS COMO BASES DE DATOS, ALMACENES DE DATOS Y OTROS SISTEMAS.

PENTAHO BIG DATA INTEGRATION: ES UNA EXTENSIÓN DE PDI DISEÑADA PARA TRABAJAR CON GRANDES VOLÚMENES DE DATOS Y ENTORNOS DE BIG DATA.

HERRAMIENTAS DE ETL (TALEND)



TALEND ES UNA PLATAFORMA DE INTEGRACIÓN DE DATOS QUE SE UTILIZA COMÚNMENTE PARA REALIZAR PROCESOS DE ETL.

PROPORCIONA UNA SERIE DE HERRAMIENTAS Y COMPONENTES QUE PERMITEN A LOS USUARIOS EXTRAER DATOS DE DIVERSAS FUENTES, TRANSFORMARLOS DE ACUERDO CON SUS NECESIDADES Y CARGARLOS EN DESTINOS ESPECÍFICOS.

TALEND DATA INTEGRATION: ESTA ES LA PARTE CENTRAL DE LA PLATAFORMA Y SE CENTRA EN EL PROCESO DE ETL.

OFRECE UNA INTERFAZ GRÁFICA PARA DISEÑAR FLUJOS DE DATOS QUE INVOLUCRAN EXTRACCIÓN, TRANSFORMACIÓN Y CARGA DE DATOS.

LOS USUARIOS PUEDEN DEFINIR TRANSFORMACIONES COMPLEJAS Y CONFIGURAR CONEXIONES A DIVERSAS FUENTES DE DATOS Y DESTINOS.

HERRAMIENTAS DE ETL (TALEND)



TALEND PROPORCIONA CONECTORES PARA UNA AMPLIA VARIEDAD DE SISTEMAS DE BIG DATA, INCLUIDOS HADOOP, SPARK Y MÁS.

ESTO PERMITE A LOS USUARIOS CONECTARSE A PLATAFORMAS PARA BIG DATA Y TRABAJAR CON SUS DATOS DE MANERA DIRECTA.

TAMBIÉN ADQUIRIÓ STITCH, PLATAFORMA DE INTEGRACIÓN DE DATOS QUE SE CENTRA EN LA CARGA DE DATOS DESDE DIVERSAS FUENTES HACIA DESTINOS DE DATOS, COMO ALMACENES DE DATOS, DATA LAKES Y BASES DE DATOS EN LA NUBE.

HERRAMIENTAS DE ETL (GLUE)




AWS GLUE ES UN SERVICIO DE EXTRACCIÓN, TRANSFORMACIÓN Y CARGA ADMINISTRADO PROPORCIONADO POR AMAZON WEB SERVICES.

ESTÁ DISEÑADO ESPECÍFICAMENTE PARA TRABAJAR CON GRANDES VOLÚMENES DE DATOS Y ENTORNOS DE BIG DATA EN LA NUBE.

GLUE AUTOMATIZA GRAN PARTE DEL PROCESO ETL AL PROPORCIONAR HERRAMIENTAS Y RECURSOS PARA DESCUBRIR, TRANSFORMAR Y MOVER DATOS DESDE DIVERSAS FUENTES HACIA DESTINOS EN AWS, COMO PUEDE SER UN HDFS QUE TENGAMOS DESPLEGADO, O UN S3.

HERRAMIENTAS DE ETL (CLOUD DATA FUSION)



CLOUD DATA FUSION ES UN SERVICIO DE GOOGLE CLOUD PLATFORM QUE OFRECE CAPACIDADES DE INTEGRACIÓN Y TRANSFORMACIÓN DE DATOS EN LA NUBE. SE BASA EN LA PLATAFORMA OPEN SOURCE APACHE NIFI Y PROPORCIONA UNA INTERFAZ VISUAL PARA DISEÑAR, EJECUTAR Y ADMINISTRAR FLUJOS DE DATOS EN ENTORNOS DE BIG DATA.

EL OBJETIVO PRINCIPAL DE CLOUD DATA FUSION ES FACILITAR EL PROCESO DE ETL Y LA PREPARACIÓN DE DATOS EN LA NUBE, PERMITIENDO A LOS USUARIOS DISEÑAR FLUJOS DE TRABAJO A TRAVÉS DE UNA INTERFAZ GRÁFICA SIN NECESIDAD DE ESCRIBIR CÓDIGO.

HERRAMIENTAS DE ETL (AZURE DATA FACTORY)



AZURE DATA FACTORY ES UN SERVICIO DE MICROSOFT AZURE QUE PERMITE LA CREACIÓN, ORQUESTACIÓN Y AUTOMATIZACIÓN DE FLUJOS DE TRABAJO DE DATOS EN LA NUBE.

SE TRATA DE UNA HERRAMIENTA DE EXTRACCIÓN, TRANSFORMACIÓN Y CARGA QUE FACILITA LA INGESTA, TRANSFORMACIÓN Y MOVIMIENTO DE DATOS DESDE DIVERSAS FUENTES HASTA DESTINOS COMO ALMACENES DE DATOS, SISTEMAS DE ANÁLISIS Y SERVICIOS EN LA NUBE.

HERRAMIENTAS DE ETL (APACHE NIFI)



APACHE NIFI ES UN PROYECTO DE CÓDIGO ABIERTO DE LA FUNDACIÓN APACHE QUE PROPORCIONA UNA PLATAFORMA DE INTEGRACIÓN DE DATOS Y AUTOMATIZACIÓN DE FLUJOS DE DATOS.


NIFI SE ENFOCA EN EL MOVIMIENTO DE DATOS DESDE MÚLTIPLES FUENTES A TRAVÉS DE UNA SERIE DE PROCESOS DE TRANSFORMACIÓN Y ENRUTAMIENTO, HASTA DESTINOS ESPECÍFICOS.

LA PRINCIPAL CARACTERÍSTICA DE NIFI ES SU CAPACIDAD PARA FACILITAR LA AUTOMATIZACIÓN Y GESTIÓN DE FLUJOS DE DATOS EN TIEMPO REAL Y EN GRANDES VOLÚMENES PROCESADOS EN BATCH.

CARACTERÍSTICAS BÁSICAS HERRAMIENTAS DE ETL

**¿CUÁLES SON LAS CARÁCTERÍSTICAS
EN COMÚN QUE HA ENCONTRADO
EN TODAS LAS DESCRIPCIONES DE
CADA HERRAMIENTA?**


CARACTERÍSTICAS BÁSICAS HERRAMIENTAS DE ETL



TODAS LAS HERRAMIENTAS MENCIONADAS TIENEN CARACTERÍSTICAS COMUNES ENTRE ELLAS.

NOS PROPORCIONAN UNA INTERFAZ GRÁFICA CON CAJAS QUE REPRESENTAN PROCESOS, Y QUE PODEMOS CONECTAR PARA MODELAR EL FLUJO DE DATOS DESDE LA EXTRACCIÓN A LA CARGA, CON TODAS LAS POSIBLES TRANSFORMACIONES.


CARACTERÍSTICAS BÁSICAS HERRAMIENTAS DE ETL



POSEEN UNA AMPLIA GAMA DE CONECTORES, LO QUE LES PERMITE CONECTARSE A TODO TIPO DE BASE O REPOSITORIO DE DATOS, TANTO PARA EXTRAER COMO PARA CARGAR DATOS.

PUEDEN SER UNA HERRAMIENTA EXCLUSIVAMENTE DE ETL, O PUEDEN TENER MÁS FUNCIONALIDADES O ESAR DENTRO DE UNA SUITE DE HERRAMIENTAS CON OTRAS FUNCIONALIDADES, NORMALMENTE ASOCIADAS A LA ANALÍTICA DE DATOS.

CARACTERÍSTICAS BÁSICAS HERRAMIENTAS DE ETL




DAN LA POSIBILIDAD DE CONVERTIR A CÓDIGO, EL FLUJO DE DATOS QUE DISEÑAMOS EN LA INTERFAZ GRÁFICA, EN ALGÚN LENGUAJE DE PROGRAMACIÓN EN PARTICULAR, EN SQL.

MANTIENEN UN REGISTRO DE METADATOS QUE DESCRIBEN LOS DATOS, LO QUE FACILITA EL SEGUIMIENTO DE LA PROCEDENCIA Y LA CALIDAD DE LOS DATOS.

SON ESCALABLES PARA MANEJAR GRANDES VOLÚMENES DE DATOS Y CRECIMIENTO FUTURO DE LA EMPRESA.

CARACTERÍSTICAS BÁSICAS HERRAMIENTAS DE ETL




PROPORCIONAN CAPACIDADES DE MONITOREO PARA SUPERVISAR EL PROGRESO DE LOS FLUJOS DE TRABAJO Y ALERTAS EN CASO DE PROBLEMAS, COMO ERRORES EN LOS DATOS O FALLAS EN LA EJECUCIÓN.

OFRECEN FUNCIONES DE SEGURIDAD PARA PROTEGER LOS DATOS DURANTE SU MOVIMIENTO Y PROCESAMIENTO, INCLUYENDO AUTENTICACIÓN Y CIFRADO.

MANTIENEN UN REGISTRO HISTÓRICO DE LAS OPERACIONES DE ETL REALIZADAS PARA RASTREAR CAMBIOS Y PARA AUDITORÍAS Y SEGUIMIENTO.

POSIBLES PREGUNTAS DE PARCIAL

- ¿Qué significa ETL y cuáles son las principales fases del proceso?
- ¿Cuáles son las fuentes de datos más comunes en un proceso ETL?
- ¿Qué debe considerarse al cargar datos en un Data Warehouse?
- Menciona y describe tres herramientas populares de ETL y sus características principales.
- ¿Cuál es el rol de la limpieza de datos dentro de la fase de transformación en ETL?
- ¿Qué beneficios aporta la automatización en los procesos ETL?
- ¿En qué se diferencian los enfoques ETL y ELT, y en qué casos se recomienda cada uno?
- ¿Cómo se puede garantizar la calidad de los datos en un proceso ETL?
- ¿Cuáles son los principales componentes que conforman un proceso ETL y cuál es la función de cada uno?
- ¿Qué tipo de transformaciones pueden realizarse en la etapa de transformación de ETL?



GRACIAS

¿ALGÚN PUNTO QUE
QUIERAN REPASAR O
PROFUNDIZAR?