



HERRAMIENTAS DE SOFTWARE PARA BIG DATA

NIFI - 06

¿QUÉ ES NIFI?



APACHE NIFI ES UN PROYECTO DE CÓDIGO ABIERTO DE LA FUNDACIÓN APACHE QUE PROPORCIONA UNA PLATAFORMA DE INTEGRACIÓN DE DATOS Y AUTOMATIZACIÓN DE FLUJOS DE DATOS.

NIFI SE ENFOCA EN EL MOVIMIENTO DE DATOS DESDE MÚLTIPLES FUENTES A TRAVÉS DE UNA SERIE DE PROCESOS DE TRANSFORMACIÓN Y ENRUTAMIENTO, HASTA DESTINOS ESPECÍFICOS. LA PRINCIPAL CARACTERÍSTICA DE NIFI ES SU CAPACIDAD PARA FACILITAR LA AUTOMATIZACIÓN Y GESTIÓN DE FLUJOS DE DATOS EN TIEMPO REAL Y EN GRANDES VOLÚMENES PROCESADOS EN BATCH.

ESTÁ PROGRAMADO EN JAVA.

HISTORIA DE NIFI



NIFI SE ORIGINÓ EN LA AGENCIA DE SEGURIDAD NACIONAL (NSA) DE LOS ESTADOS UNIDOS Y FUE DESARROLLADO POR EL GRUPO DE SOLUCIONES DE CÓDIGO ABIERTO (OSSG) DE LA NSA.

LA NSA LO DESARROLLÓ CON EL PROPÓSITO DE GESTIONAR Y AUTOMATIZAR EL FLUJO DE DATOS EN ENTORNOS COMPLEJOS DE RED Y SEGURIDAD.

EN 2014, LA NSA DONÓ APACHE NIFI A LA ASF COMO UN PROYECTO DE CÓDIGO ABIERTO BAJO LA LICENCIA APACHE LICENSE 2.0. DESDE ENTONCES, NIFI HA EXPERIMENTADO UN DESARROLLO Y UNA ADOPCIÓN SIGNIFICATIVOS EN LA COMUNIDAD DE CÓDIGO ABIERTO Y EN LA INDUSTRIA EN GENERAL.

HISTORIA DE NIFI



APACHE NIFI SE HA CONVERTIDO EN UNA HERRAMIENTA POPULAR PARA EL PROCESAMIENTO DE DATOS EN TIEMPO REAL Y LA GESTIÓN DE FLUJOS DE DATOS EN UNA VARIEDAD DE ENTORNOS, DESDE LA INGESTIÓN DE DATOS EN SISTEMAS DE BIG DATA HASTA LA AUTOMATIZACIÓN DE FLUJOS DE TRABAJO EN LA NUBE.

SU DISEÑO MODULAR Y SU CAPACIDAD PARA CONECTAR CON NUMEROSOS SISTEMAS Y FUENTES DE DATOS LO HACEN ADECUADO PARA UNA AMPLIA GAMA DE CASOS DE USO EN LA GESTIÓN DE DATOS Y LA INTEGRACIÓN DE SISTEMAS.

CARACTERÍSTICAS GENERALES



INTERFAZ GRÁFICA Y ARRASTRAR Y SOLTAR:

NIFI OFRECE UNA INTERFAZ DE USUARIO GRÁFICA, FÁCIL DE USAR, QUE PERMITE A LOS USUARIOS DISEÑAR FLUJOS DE DATOS ARRASTRANDO Y CONECTANDO COMPONENTES EN UN LIENZO.

CONECTIVIDAD AMPLIA:

PROPORCIONA UNA AMPLIA GAMA DE CONECTORES PARA INTERACTUAR CON DIVERSAS FUENTES Y DESTINOS DE DATOS, INCLUIDAS BASES DE DATOS, SERVICIOS WEB, SISTEMAS DE MENSAJERÍA, SISTEMAS DE ARCHIVOS Y MÁS.

CARACTERÍSTICAS GENERALES



PROCESAMIENTO EN BATCH Y EN TIEMPO REAL:

NIFI ESTÁ DISEÑADO PARA ADMITIR FLUJOS DE DATOS EN TIEMPO REAL, LO QUE SIGNIFICA QUE PUEDES MOVER Y TRANSFORMAR DATOS A MEDIDA QUE FLUYEN, ADEMÁS DE PROCESARLOS POR LOTES.

TRANSFORMACIONES Y ENRIQUECIMIENTO:

PERMITE REALIZAR TRANSFORMACIONES EN LOS DATOS A MEDIDA QUE SE MUEVEN POR LOS FLUJOS, LO QUE INCLUYE FILTRADO, ENRIQUECIMIENTO, ENMASCARAMIENTO Y MÁS.

CARACTERÍSTICAS GENERALES



ORQUESTACIÓN Y ENRUTAMIENTO:

SE PUEDEN DISEÑAR FLUJOS DE DATOS COMPLEJOS QUE INVOLUCREN MÚLTIPLES ETAPAS DE PROCESAMIENTO Y ENRUTAMIENTO BASADO EN REGLAS.

PRIORIZACIÓN Y BALANCEO DE CARGA:

NIFI PERMITE ESTABLECER REGLAS DE PRIORIZACIÓN PARA DETERMINAR CÓMO SE DEBEN GESTIONAR LOS FLUJOS DE DATOS Y CÓMO SE DISTRIBUYEN LAS CARGAS DE TRABAJO.

CARACTERÍSTICAS GENERALES



SEGURIDAD Y CONTROL:

PROPORCIONA CAPACIDADES DE SEGURIDAD Y AUTENTICACIÓN PARA PROTEGER LOS DATOS Y GARANTIZAR QUE SOLO USUARIOS AUTORIZADOS PUEDAN ACCEDER A LOS FLUJOS DE DATOS.

ESCALABILIDAD:

NIFI ESCALA HORIZONTALMENTE PARA MANEJAR VOLÚMENES DE DATOS CRECIENTES.

CARACTERÍSTICAS GENERALES



MONITOREO Y GESTIÓN:

OFRECE HERRAMIENTAS PARA MONITOREAR Y ADMINISTRAR LOS FLUJOS DE DATOS, LO QUE PERMITE IDENTIFICAR Y RESOLVER PROBLEMAS EN TIEMPO REAL.

EXTENSIBILIDAD Y COMUNIDAD ACTIVA:

COMO PROYECTO DE CÓDIGO ABIERTO BAJO LA FUNDACIÓN APACHE, NIFI CUENTA CON UNA COMUNIDAD ACTIVA QUE CONTRIBUYE A SU DESARROLLO Y MEJORA CONSTANTE. ADEMÁS, OFRECE EXTENSIONES Y PLUGINS PERSONALIZADOS.

CARACTERÍSTICAS GENERALES



ZERO-MASTER CLUSTERING:

NIFI EMPLEA UN PARADIGMA DE CLUSTERING SIN MAESTRO. CADA NODO EN EL CLÚSTER REALIZA LAS MISMAS TAREAS EN LOS DATOS, PERO CADA UNO OPERA EN UN CONJUNTO DIFERENTE DE DATOS.

UNO DE LOS NODOS SE ELIGE AUTOMÁTICAMENTE COMO COORDINADOR DEL CLÚSTER. TODOS LOS NODOS EN EL CLÚSTER ENVIARÁN INFORMACIÓN DE LATIDO/ESTADO A ESTE NODO, Y ESTE NODO ES RESPONSABLE DE DESCONECTAR A LOS NODOS QUE NO REPORTAN NINGÚN ESTADO DE LATIDO DURANTE ALGÚN TIEMPO.

ADEMÁS, CUANDO UN NUEVO NODO ELIGE UNIRSE AL CLÚSTER, PRIMERO DEBE CONECTARSE AL COORDINADOR DEL CLÚSTER ACTUALMENTE ELEGIDO PARA OBTENER EL FLUJO MÁS ACTUALIZADO.

PROCESSORS



LOS PROCESSORS, SON LA UNIDAD BÁSICA POR LA QUE ESTÁ FORMADA UN FLUJO DE DATOS.

HAY MÁS DE 300 CONECTORES DISTINTOS, CADA UNO CON SU FUNCIONALIDAD. ALGUNOS PARA CONECTARSE A FUENTES DE DATOS Y LEER, OTROS PARA CARGAR DATOS A UNA FUENTE, Y EL RESTO PARA TODAS LAS POSIBLES TRANSFORMACIONES, GESTIÓN DE LOS DATOS Y METADATOS, Y DISEÑO DEL FLUJO DE DATOS.

NIFI ES CONCURRENT, PERMITIENDO QUE CORRAN MÚLTIPLES FLUJOS DE DATOS SIMULTÁNEAMENTE. LOS PROCESSORS ABSTRAEN AL USUARIO DE LA COMPLEJIDAD DE PROGRAMAR EL ETL, Y APORTAN LA SENSACIÓN DE FLUJO DE DATOS, NO TAN EVIDENTE AL PROGRAMAR Y LEER EL CÓDIGO, SOBRE TODO PARA TÉCNICOS NO INFORMÁTICOS.

CONNECTORS



LOS PROCESSORS ESTÁN UNIDOS POR CONECTORES (CONNECTORS) QUE DETERMINAN LA DIRECCIÓN DEL FLUJO DE DATOS Y EL ÓRDEN EN QUE SE EJECUTAN LOS PROCESSORS.

TAMBIÉN DETERMINAN LAS CAUSÍSTICAS QUE PERMITEN AVANZAR AL FLUJO.

POR EJEMPLO, EN CASO DE FALLA, ÉXITO, U OTROS.

CANVAS



ES EL FONDO BLANCO CUADRICULADO SOBRE EL CUÁL COLOCAMOS, ARRASTRANDO CON EL MOUSE, LOS DISTINTOS PROCESSORS O PROCESS GROUPS.

LA GRILLA CUADRICULADA SIRVE PARA ORDENAR, ALINEAR Y PROLIJAR LOS DIFERENTES PROCESSORS Y SUS RESPECTIVOS CONECTORES.

PROCESS GROUP



DE FORMA DE ORDENAR LOS DISTINTOS FLUJOS DE DATOS PARA ETL QUE SE CONSTRUYEN, NIFI PROVEE LOS PROCESS GROUPS.

SIRVEN PARA CONTENER OTROS PROCESS GROUPS, O FLUJOS DE DATOS, Y MONITOREARLOS ESPECIFICAMENTE, YA QUE NOS DAN INFORMACIÓN SOBRE SU CONTENIDO.



Get CSV file
GetFile 1.9.1
org.apache.nifi - nifi-standard-nar

In	0 (0 bytes)	5 min
Read/Write	0 bytes / 0 bytes	5 min
Out	0 (0 bytes)	5 min
Tasks/Time	0 / 00:00:00.000	5 min

Name files loaded
Queued 0 (0 bytes)



Validate CSV Data type - line by line
ValidateCsv 1.9.1
org.apache.nifi - nifi-standard-nar

In	0 (0 bytes)	5 min
Read/Write	0 bytes / 0 bytes	5 min
Out	0 (0 bytes)	5 min
Tasks/Time	0 / 00:00:00.000	5 min

Name validation succeeded
Queued 0 (0 bytes)



Save validated CSV
PutFile 1.9.1
org.apache.nifi - nifi-standard-nar

In	0 (0 bytes)	5 min
Read/Write	0 bytes / 0 bytes	5 min
Out	0 (0 bytes)	5 min
Tasks/Time	0 / 00:00:00.000	5 min

FLOWFILES



FLOWFILES ES EL NOMBRE QUE RECIBE LOS DATOS Y SUS METADATOS DENTRO DE NIFI.

CUANDO UN FLUJO DE DATOS ESTÁ ACTIVO VEMOS QUE SE VA AGRUPANDO EN FILAS (QUEUE) EN LOS DISTINTOS PROCESSORS O CONNECTORS.

LA REFERENCIA A LOS DATOS ES EL CONTENIDO, Y ALGUNOS METADATOS USADOS FRECUENTEMENTE SE ENCUENTRAN BAJO EL NOMBRE DE FILE NAME, FILE PATH O ID.

EL CONTENIDO MISMO NO VIAJA EN EL FLOWFILE SINO UN PUNTERO QUE HACE REFERENCIA AL MISMO, DENTRO DEL REPOSITORIO DE CONTENIDO PROPIO DE NIFI.

REPOSITORIO DE CONTENIDO



EL REPOSITORIO DE CONTENIDO ES SIMPLEMENTE EL LUGAR EN EL ALMACENAMIENTO LOCAL DONDE RESIDE EL CONTENIDO DE TODOS LOS FLOWFILES.

NO TODOS LOS PROCESADORES NECESITAN ACCEDER AL CONTENIDO DEL FLOWFILE PARA REALIZAR SUS OPERACIONES, POR EJEMPLO, LA AGREGACIÓN DEL CONTENIDO DE DOS FLOWFILES NO REQUIERE CARGAR SU CONTENIDO EN MEMORIA.

REPOSITORIO DE CONTENIDO



CUANDO UN PROCESADOR MODIFICA EL CONTENIDO DE UN FLOWFILE, LOS DATOS ANTERIORES SE CONSERVAN.

NIFI REALIZA UNA COPIA AL ESCRIBIR, MODIFICA EL CONTENIDO MIENTRAS LO COPIA A UNA NUEVA UBICACIÓN.

LA INFORMACIÓN ORIGINAL SE MANTIENE INTACTA EN EL REPOSITORIO DE CONTENIDO.

PROVENANCE REPOSITORY



NIFI PROPORCIONA OTRA HERRAMIENTA PARA REALIZAR UN SEGUIMIENTO COMPLETO DE LA HISTORIA DE TODOS LOS FLOWFILES EN EL FLUJO: EL REPOSITORIO DE EVIDENCIA (PROVENANCE REPOSITORY).

CADA VEZ QUE SE MODIFICA UN FLOWFILE, NIFI TOMA UN SNAPSHOT DEL FLOWFILE Y SU CONTEXTO EN ESE PUNTO. EL NOMBRE DE ESTE SNAPSHOT EN NIFI ES UN EVENTO DE EVIDENCIA.

EL REPOSITORIO DE EVIDENCIA REGISTRA EVENTOS DE EVIDENCIA (PROVENANCE EVENTS).

LA EVIDENCIA NOS PERMITE RASTREAR LA TRAZABILIDAD DE LOS DATOS Y CONSTRUIR LA CADENA COMPLETA DE CUSTODIA PARA CADA PIEZA DE INFORMACIÓN PROCESADA EN NIFI.

PROVENANCE VS CONTENT




EL REPOSITORIO DE CONTENIDO ES UN LOG QUE CONTIENE SOLO EL ESTADO MÁS RECIENTE DE LOS FLOWFILES EN USO EN EL SISTEMA. ES LA IMAGEN MÁS RECIENTE DEL FLUJO Y PERMITE RECUPERARSE RÁPIDAMENTE DE UNA INTERRUPCIÓN.

POR OTRO LADO, EL REPOSITORIO DE EVIDENCIA ES MÁS EXHAUSTIVO, YA QUE REALIZA UN SEGUIMIENTO DEL CICLO DE VIDA COMPLETO DE CADA FLOWFILE QUE HA ESTADO EN EL FLUJO.

POSIBLES PREGUNTAS DE PARCIAL

- ¿Qué es Apache NiFi?
- Menciona al menos tres características generales de Apache NiFi que lo hacen destacar en la gestión de flujos de datos.
- ¿Qué son los FlowFiles en Apache NiFi y cómo se gestionan los datos y metadatos relacionados con ellos?
- Diferencia entre el *Repositorio de Contenido* y el *Repositorio de Evidencia* en Apache NiFi.
- ¿Cuál es la función de los Process Groups en NiFi y cómo contribuyen a la organización de los flujos de datos?
- ¿Qué tipos de transformaciones puede realizar Apache NiFi en los datos mientras se mueven por los flujos? Da ejemplos.
- Explica el concepto de clustering sin maestro (Zero-Master Clustering) en Apache NiFi y su importancia.
- ¿Por qué es relevante la comunidad activa en el desarrollo de Apache NiFi? ¿Qué beneficios aporta la extensibilidad del software?
- ¿Qué ventajas ofrece la interfaz gráfica de NiFi en comparación con otras herramientas?
- ¿Cuál es el papel de los conectores en Apache NiFi y cómo determinan el flujo de datos entre procesadores?
- ¿Qué función cumple el Canvas en Apache NiFi y cómo ayuda a los usuarios a organizar sus flujos de datos?
- Explica qué son los Processors en NiFi y menciona al menos tres tipos de procesadores con sus funciones específicas.



GRACIAS

¿ALGÚN PUNTO QUE
QUIERAN REPASAR O
PROFUNDIZAR?