





HERRAMIENTAS DE SOFTWARE PARA BIG DATA

MOTORES DE PROCESAMIENTO DE DATOS - 07

COMPONENTES DEL DATALAKE



¿QUÉ SON LOS MOTORES DE PROCESAMIENTO DE DATOS?




UN MOTOR DE PROCESAMIENTO DE DATOS ES UNA PARTE FUNDAMENTAL DE CUALQUIER SISTEMA O PLATAFORMA DISEÑADA PARA EL PROCESAMIENTO Y ANÁLISIS DE DATOS.

ES UN COMPONENTE DE SOFTWARE QUE SE ENCARGA DE EJECUTAR OPERACIONES ESPECÍFICAS RELACIONADAS CON LA MANIPULACIÓN, TRANSFORMACIÓN, CONSULTA O ANÁLISIS DE DATOS.

ESTOS MOTORES ESTÁN DISEÑADOS PARA REALIZAR TAREAS DE PROCESAMIENTO DE DATOS DE MANERA EFICIENTE.

TAREAS DE UN MOTOR DE PROCESAMIENTO DE DATOS




PROCESAMIENTO DE DATOS EN BRUTO:

ESTO IMPLICA LA CAPACIDAD DE LEER, ESCRIBIR Y MANIPULAR DATOS EN DIFERENTES FORMATOS Y DESDE DIVERSAS FUENTES.

TRANSFORMACIÓN DE DATOS:

LOS MOTORES DE PROCESAMIENTO DE DATOS PUEDEN APLICAR TRANSFORMACIONES A LOS DATOS, COMO LA LIMPIEZA DE DATOS, LA AGREGACIÓN, LA NORMALIZACIÓN, LA UNIÓN DE CONJUNTOS DE DATOS Y LA CONVERSIÓN DE FORMATOS. TODAS LAS TRANSFORMACIONES YA VISTAS EN HERRAMIENTAS DE ETL.

TAREAS DE UN MOTOR DE PROCESAMIENTO DE DATOS




ANÁLISIS DE DATOS:

PUEDEN EJECUTAR CONSULTAS Y ANÁLISIS COMPLEJOS EN LOS DATOS, LO QUE INCLUYE OPERACIONES DE AGREGACIÓN, FILTRADO, CLASIFICACIÓN Y CÁLCULOS ESTADÍSTICOS.

PROCESAMIENTO EN TIEMPO REAL:

ALGUNOS MOTORES DE PROCESAMIENTO DE DATOS ESTÁN DISEÑADOS ESPECÍFICAMENTE PARA EL PROCESAMIENTO DE DATOS EN TIEMPO REAL, LO QUE PERMITE ANALIZAR Y TOMAR DECISIONES BASADAS EN DATOS A MEDIDA QUE LLEGAN. OTROS TAMBIÉN PUEDEN PROCESAR EN BATCH, O AMBAS.

TAREAS DE UN MOTOR DE PROCESAMIENTO DE DATOS




OPTIMIZACIÓN DE CONSULTAS:

LOS MOTORES DE PROCESAMIENTO DE DATOS A MENUDO ESTÁN OPTIMIZADOS PARA OPTIMIZAR LA EJECUCIÓN DE LAS CONSULTAS SOBRE LOS DATOS QUE REALIZAN LOS USUARIOS PARA HACER EL USO MÁS EFICIENTE POSIBLE DE LOS RECURSOS. TIENEN SUS PROPIOS PROCESOS INTERNOS DE OPTIMIZACIÓN, QUE TRABAJAN INDEPENDIENTE DE LA CONSULTA REALIZADA POR EL USUARIO.

PROCESAMIENTO DISTRIBUIDO:

MUCHOS MOTORES DE PROCESAMIENTO DE DATOS ESTÁN DISEÑADOS PARA FUNCIONAR EN CLÚSTERES DE SERVIDORES PARA DISTRIBUIR LA CARGA DE TRABAJO Y ESCALAR HORIZONTALMENTE. EL PROCESAMIENTO ENTONCES OCURRE EN PARALELO.


¿SUSTITUYEN A LAS HERRAMIENTAS DE ETL?



ES TEÓRICAMENTE POSIBLE SUSTITUIR CON UNA DE ESTAS HERRAMIENTAS A UNA HERRAMIENTA DE ETL.

TENEMOS LA POSIBILIDAD DE LEER Y ESCRIBIR DE VARIAS FUENTES DE DATOS Y REALIZAR TODAS LAS TRANSFORMACIONES DE DATOS QUE SE NECESITEN, UNA VEZ LOS ARCHIVOS ESTÉN ALMACENADOS EN NUESTRO SISTEMA DE ARCHIVOS DISTRIBUIDOS.

¿SUSTITUYEN A LAS HERRAMIENTAS DE ETL?




SIN EMBARGO, NO SE HACE ASÍ.

LAS VENTAJAS DE LAS HERRAMIENTAS DE ETL SON SOBRE TODO A LA HORA DE PROGRAMAR INGESTAS DE DATOS A NUESTRO SISTEMA DE ARCHIVOS DISTRIBUIDOS.

MIENTRAS QUE POR EL GRAN VOLUMEN DE DATOS, ALGUNOS TIPOS DE TRANSFORMACIONES SON MÁS EFICIENTES SI SON REALIZADOS EN NUESTRO HDFS.

ALGUNAS DE ESTAS TRANSFORMACIONES SON LAS AGRUPACIONES, JOINS ENTRE TABLAS Y CÁLCULOS DE AGREGACIONES, LAS CUALES REQUIEREN DE MAYORES RECURSOS DE DISCO Y SOBRE TODO MEMORIA:

¿SUSTITUYEN A LAS HERRAMIENTAS DE ETL?



LAS HERRAMIENTAS DE ETL ENTONCES TOMAN EL PAPEL DE HERRAMIENTA PARA INGESTAR DATOS O EXTRAER COPIAS DE LOS DATOS DEL DATALAKE. EL GRUESO DE LAS TRANSFORMACIONES QUE REALIZAN SON SOBRE LA METADATA.

LAS INGESTAS DE LOS DATOS SON DESDE SU FUENTE ORIGINAL O UNA COPIA DE ESTA. COMO YA EXPLICAMOS, LEER DIRECTAMENTE DE LAS FUENTES, ES COSTOSO PARA BASES DE DATOS TRANSACCIONALES QUE ESTAN PERSISTIENDO LOS DATOS OPERATIVOS.

Y LA EXTRACCIÓN DE DATOS DESDE EL DATALAKE ES DE DATOS YA REFINADOS Y ENRIQUECIDOS A PARTIR DE VARIAS FUENTES PARA SER USADOS POR MIEMBROS DE LA ORGANIZACIÓN U OTROS SISTEMAS.

¿CÓMO USAMOS LOS MOTORES DE PROCESAMIENTO DE DATOS?



UNA VEZ LOS DATOS SON INGESTADOS AL DATALAKE, PODEMOS PROCESARLOS PARA SU REFINADO. COMO EXPLICAMOS ANTERIORMENTE, NO TODAS LAS TRANSFORMACIONES SON REALIZADAS CON LAS HERRAMIENTAS DE ETL.

EL PRIMER PASO ES GUARDAR UNA COPIA DENTRO DEL DATALAKE DEL ARCHIVO EN SU FORMATO ORIGINAL.

LUEGO SI SE REALIZAN TODAS LAS TRANSFORMACIONES FALTANTES.

¿CÓMO USAMOS LOS MOTORES DE PROCESAMIENTO DE DATOS?



ESTE PRIMER PROCESO SE LO CONOCE COMO REFINADO DE DATOS.

SE APLICA SOBRE DATOS ESTRUCTURADOS, LLEVANDOLOS A UN FORMATO TABULAR QUE PERMITA LA INTEGRACIÓN DE DATOS PROVENIENTES DE DISTINTAS FUENTES.

¿CÓMO USAMOS LOS MOTORES DE PROCESAMIENTO DE DATOS?



LUEGO DE REFINADO DE DATOS DEBEMOS ELEGIR QUE FORMA DE MODELAR LOS DATOS UTILIZAREMOS.

VAMOS A TENER QUE ADAPTAR LOS DISTINTOS ARCHIVOS CON DATOS PARA LA ESTRUCTURA QUE UTILICEMOS.

LUEGO DE ESTE PROCESAMIENTO, NUESTROS ARCHIVOS QUEDAN PRONTOS PARA SER CONSUMIDOS POR HERRAMIENTAS DE CONSULTA DE DATOS EN FORMATO TABLULAR.

¿CÓMO USAMOS LOS MOTORES DE PROCESAMIENTO DE DATOS?



UNA VEZ LOS DATOS ESTÉN SIENDO CONSUMIDOS A TRAVÉS DE TABLAS, LOS ANALÍSTAS DE DATOS PUEDEN HACER CONSULTAS SOBRE LOS MISMOS.

LOS MOTORES DE PROCESAMIENTO DE DATOS, TAMBIÉN PUEDEN SER UTILIZADOS PARA HACER CONSULTAS SOBRE ESTAS TABLAS, PUDIENDO TAMBIÉN ARMAR PROCESOS QUE LUEGO SON AUTOMATIZADOS UNA VEZ TENAMOS ARMADO UN ANÁLISIS QUE QUIERAMOS DEJAR PRONTO PARA SER UTILIZADO POR EL RESTO DE LA ORGANIZACIÓN.


¿CÓMO USAMOS LOS MOTORES DE PROCESAMIENTO DE DATOS?



CON ESTOS PROCESOS QUE ARMAMOS PODEMOS CONSTRUIR DATAMARTS (CONJUNTOS DE DATOS RELATIVOS A UN TEMA EN PARTICULAR) O PODEMOS DEJAR PRONTO UN ANÁLISIS FINAL QUE VAYA A SER EXTRAÍDO DEL DATALAKE.

POSIBLES PREGUNTAS DE PARCIAL

- ¿Qué es un motor de procesamiento de datos y cuál es su función principal dentro de una plataforma de Big Data?
- Mencionar y describir al menos tres tareas que puede realizar un motor de procesamiento de datos.
- ¿Cuál es la diferencia entre el procesamiento de datos en tiempo real y el procesamiento en lotes?
- ¿Por qué no se suelen sustituir completamente las herramientas de ETL por motores de procesamiento de datos, a pesar de que es teóricamente posible?
- Explicar en qué consiste el “refinado de datos” dentro del datalake y qué objetivo tiene.
- ¿Qué tipo de transformaciones son más eficientes cuando se realizan con motores de procesamiento de datos en lugar de herramientas de ETL?
- ¿Cuál es el rol de las herramientas de ETL en la relación con el datalake y los motores de procesamiento de datos?
- Describir el proceso completo desde la ingesta de datos hasta que estos están disponibles para su consulta en formato tabular.
- ¿Qué es un datamart y cómo se puede construir utilizando motores de procesamiento de datos?
- ¿Cómo contribuyen los motores de procesamiento de datos a la automatización de análisis dentro de una organización?



GRACIAS

¿ALGÚN PUNTO QUE
QUIERAN REPASAR O
PROFUNDIZAR?