



HERRAMIENTAS DE SOFTWARE PARA BIG DATA

SPARK - 08

¿QUÉ ES SPARK?



APACHE SPARK ES UN FRAMEWORK DE PROCESAMIENTO DE DATOS EN CÓDIGO ABIERTO QUE SE UTILIZA PARA EL PROCESAMIENTO Y ANÁLISIS DE GRANDES VOLÚMENES DE DATOS DE MANERA EFICIENTE Y ESCALABLE.

FUE DESARROLLADO INICIALMENTE EN LA UNIVERSIDAD DE CALIFORNIA, BERKELEY, Y DESDE ENTONCES HA GANADO UNA AMPLIA ADOPCIÓN EN LA INDUSTRIA Y EN LA COMUNIDAD DE CÓDIGO ABIERTO.

¿QUÉ ES SPARK?



APACHE SPARK FUE CREADO EN LA UNIVERSIDAD DE CALIFORNIA, BERKELEY, EN EL LABORATORIO DE AMPLAB (LABORATORIO DE ANÁLISIS DE DATOS EN MEMORIA DE BERKELEY).

EL PROYECTO FUE INICIADO POR MATEI ZAHARIA EN 2009 COMO PARTE DE SU TESIS DOCTORAL.

MATEI ZAHARIA ES UN CIENTÍFICO DE DATOS Y PROGRAMADOR RUMANO-CANADIENSE QUE LIDERÓ EL DESARROLLO INICIAL DE SPARK Y CONTRIBUYÓ SIGNIFICATIVAMENTE A SU DISEÑO Y ARQUITECTURA.

¿QUÉ ES SPARK?



PARA EL AÑO 2010 EL CÓDIGO DE SPARK SE PUBLICÓ COMO OPEN SOURCE, Y PARA EL AÑO 2013 YA FORMABA PARTE DE LA FUNDACIÓN APACHE Y EN 2014 LA APACHE FOUNDATION LE DIÓ LA CATEGORÍA DE “TOP LEVEL PROJECT”.

DESDE ENTONCES SE CONVIRTIÓ EN UNO DE LOS MÁS POPULARES FRAMEWORKS PARA PROCESAMIENTO DE DATOS EN LA INDUSTRIA.

EL OBJETIVO DE SPARK ES PROVEER UN FRAMEWORK DISTRIBUIDO, DE PROPÓSITO GENERAL, PARA PROCESAR GRANDES VOLUMENES DE DATOS.

DISEÑADO PARA SUPERAR LAS LIMITACIONES DE MAPREDUCE, EL FRAMEWORK DE PROCESAMIENTO DE BIGDATA NATIVO DE HADOOP.

¿QUÉ ES SPARK?



SPARK SE DESTACA POR SU CAPACIDAD PARA REALIZAR OPERACIONES DE PROCESAMIENTO EN MEMORIA, LO QUE SIGNIFICA QUE PUEDE CARGAR DATOS EN LA MEMORIA RAM DE UN CLÚSTER DE SERVIDORES Y REALIZAR OPERACIONES DE PROCESAMIENTO DE DATOS EN TIEMPO REAL DE MANERA MUY RÁPIDA.

SPARK PROPORCIONA UN FRAMEWORK UNIFICADO Y DE PROPÓSITO GENERAL PARA REALIZAR DIFERENTES TAREAS QUE ANTERIORMENTE HABRÍA REQUERIDO DIFERENTES MOTORES, CÓMO EL PROCESAMIENTO EN BATCH O EN TIEMPO REAL.

CARACTERÍSTICAS DE SPARK



PROCESAMIENTO EN MEMORIA:

SPARK ALMACENA DATOS EN MEMORIA, LO QUE ACELERA SIGNIFICATIVAMENTE EL PROCESAMIENTO EN COMPARACIÓN CON SOLUCIONES DE PROCESAMIENTO EN DISCO COMO HADOOP MAPREDUCE.

SOPORTE PARA MÚLTIPLES LENGUAJES:

SPARK OFRECE APIS EN VARIOS LENGUAJES DE PROGRAMACIÓN, COMO SCALA, JAVA, PYTHON Y R, LO QUE FACILITA SU ADOPCIÓN POR PARTE DE DESARROLLADORES CON DIFERENTES HABILIDADES.

CARACTERÍSTICAS DE SPARK



LIBRERÍAS EXTENSAS:

SPARK CUENTA CON UN ECOSISTEMA DE LIBRERÍAS ADICIONALES, COMO SPARK SQL (PARA PROCESAMIENTO SQL), SPARK STREAMING (PARA PROCESAMIENTO EN TIEMPO REAL), MLLIB (PARA MACHINE LEARNING) Y GRAPHX (PARA PROCESAMIENTO DE GRÁFOS), LO QUE LO HACE VERSÁTIL PARA UNA VARIEDAD DE APLICACIONES.

ESCALABILIDAD:

PUEDE ESCALAR HORIZONTALMENTE PARA MANEJAR GRANDES VOLUMENES DE DATOS Y CARGAS DE TRABAJO INTENSIVAS.

CARACTERÍSTICAS DE SPARK



INTEGRACIÓN CON SISTEMAS DE ALMACENAMIENTO DE DATOS:

SE INTEGRA CON VARIOS SISTEMAS DE ALMACENAMIENTO DE DATOS, INCLUYENDO HADOOP HDFS, APACHE HBASE, APACHE HIVE Y BASES DE DATOS RELACIONALES, LO QUE FACILITA LA INGESTIÓN Y EXPORTACIÓN DE DATOS HACIA Y DESDE UN DATALAKE.

MODELO DE PROGRAMACIÓN UNIFICADO:

SPARK OFRECE UN MODELO DE PROGRAMACIÓN UNIFICADO QUE PERMITE A LOS DESARROLLADORES ESCRIBIR CÓDIGO UNA VEZ Y EJECUTARLO TANTO EN TAREAS DE PROCESAMIENTO EN BATCH COMO EN STREAMING.

CARACTERÍSTICAS DE SPARK



COMUNIDAD ACTIVA:

SPARK CUENTA CON UNA COMUNIDAD DE DESARROLLO ACTIVA Y ES RESPALDADO POR ORGANIZACIONES LÍDERES EN TECNOLOGÍA, LO QUE GARANTIZA UN DESARROLLO CONTINUO Y UN SÓLIDO SOPORTE. (DATABRICKS Y APACHE SOFTWARE FOUNDATION)

COMPATIBILIDAD CON LA NUBE:

PUEDE EJECUTARSE EN PLATAFORMAS DE NUBE COMO AMAZON WEB SERVICES (AWS), GOOGLE CLOUD PLATFORM (GCP) Y MICROSOFT AZURE, LO QUE FACILITA LA ADOPCIÓN EN ENTORNOS DE NUBE E INTEGRACIÓN CON LOS SERVICIOS NATIVOS QUE OFRECEN LAS MISMAS.

SPARK VS HADOOP MAPREDUCE



VS



SPARK PROPORCIONA OPERADORES DE ALTO NIVEL COMO MAP, FILTROS, ETC., QUE FACILITAN EL TRABAJO DEL DESARROLLADOR.

SI UTILIZARAN DIRECTAMENTE MAPREDUCE, LOS DESARROLLADORES DEBERÍAN CODIFICAR A MANO CADA OPERACIÓN.

SPARK ES 100 VECES MÁS RÁPIDO QUE MAPREDUCE CUANDO SE EJECUTA SPARK EN MEMORIA Y 10 VECES MÁS RÁPIDO QUE MAPREDUCE CUANDO SE EJECUTA SPARK EN DISCO AL REDUCIR LA CANTIDAD DE CICLOS DE LECTURA Y ESCRITURA EN EL DISCO Y ALMACENAR DATOS INTERMEDIOS EN LA MEMORIA.

SPARK VS HADOOP MAPREDUCE



VS




MAPREDUCE LEE Y ESCRIBE DESDE EL DISCO, LO QUE ENLENTECE LA VELOCIDAD DE PROCESAMIENTO Y LA EFICIENCIA GENERAL.

SPARK PROPORCIONA UN SHELL INTERACTIVO PARA APRENDER, HACER PRUEBAS Y EXPLORAR LOS DATOS.

MAPREDUCE NO PROPORCIONA NINGÚN SHELL INTERACTIVO.

RDD



LA BASE DE SPARK SON LOS RDD (RESILIENT DISTRIBUTED DATASET).


UN RDD ES UNA ABSTRACCIÓN DE COLECCIÓN DE OBJETOS DE SOLO LECTURA, DISTRIBUIDOS EN UN CLÚSTER DE SERVIDORES.

ES TOLERANTE A FALLOS Y ESTÁ COMPUESTO POR ELEMENTOS QUE SE PUEDEN PROCESAR EN PARALELO.

LOS RDDS SE UTILIZAN EN SPARK PARA REPRESENTAR CONJUNTOS DE DATOS DISTRIBUIDOS QUE SE PUEDEN DIVIDIR Y PROCESAR EN MÚLTIPLES NODOS DE UN CLÚSTER DE MANERA PARALELA.

SE PUEDE CREAR UN RDD A PARTIR DE UN ARCHIVOS DE TEXTO, BASES DE DATOS SQL, O NOSQL, ARCHIVOS EN HDFS O ARCHIVOS GUARDADOS EN LA NUBE, ENTRE OTROS.

CARACTERÍSTICAS RDD




DISTRIBUCIÓN Y PARALELISMO:

LOS RDDS PERMITEN QUE LOS DATOS SE DISTRIBUYAN EN MÚLTIPLES NODOS DE UN CLÚSTER SPARK Y SE PROCESAN EN PARALELO. ESTO FACILITA EL PROCESAMIENTO EFICIENTE DE GRANDES VOLÚMENES DE DATOS.

INMUTABILIDAD:

LOS RDDS SON INMUTABLES, LO QUE SIGNIFICA QUE UNA VEZ QUE SE CREA UN RDD, NO SE PUEDEN MODIFICAR. SIN EMBARGO, SE PUEDEN REALIZAR TRANSFORMACIONES EN UN RDD, Y A PARTIR DE LAS MISMAS SE CREA UN NUEVO RDD, DEJANDO INTACTO AL ANTERIOR.

CARACTERÍSTICAS RDD



TOLERANCIA A FALLOS:

LOS RDDS SON TOLERANTES A FALLOS.


ESTO SIGNIFICA QUE SI UN NODO EN EL CLÚSTER FALLA DURANTE UN CÁLCULO, SPARK PUEDE RECONSTRUIR AUTOMÁTICAMENTE LOS DATOS PERDIDOS EN OTRO NODO Y CONTINUAR EL PROCESAMIENTO.

OPERACIONES:

LOS RDDS ADMITEN DOS TIPOS DE OPERACIONES: TRANSFORMACIONES Y ACCIONES.

LAS TRANSFORMACIONES SON OPERACIONES QUE CREAN UN NUEVO RDD A PARTIR DE UNO EXISTENTE, MIENTRAS QUE LAS ACCIONES DEVUELVEN RESULTADOS O VALORES AL PROGRAMA PRINCIPAL.

CARACTERÍSTICAS RDD




LOS RDD PERMITEN REALIZAR FUNCIONES DE MAPREDUCE, PERO TAMBIÉN, OPERACIONES DE JOINS ENTRE DATASETS, FILTRADO Y AGREGACIONES.

TODOS EL PROCESAMIENTO DE LOS RDD ES HECHO EN MEMORIA.

LA COMPLEJIDAD DEL RDD ES ESCONDIDA AL USUARIO FINAL PARA QUE NO TENGA QUE PREOCUPARSE MÁS QUE DE LAS OPERACIONES QUE QUIERE REALIZAR SOBRE LOS DATOS. SUPERANDO LA FORMA TRADICIONAL DE PROGRAMAR TAREAS DE MAPREDUCE.

PROCESAMIENTO RDD



EL PROCESAMIENTO DE UN RDD SE HACE MEDIANTE DRIVERS Y EXECUTORS.


AL EJECUTAR UN PROGRAMA UN DRIVER CREA UN SPARK CONTEXT.

EL SPARK CONTEXT ES UN ORQUESTADOR QUE LEE EL CÓDIGO Y CONSIDERA EL TRABAJO QUE DEBE REALIZARSE.

EL TRABAJO A REALIZAR SE DIVIDE EN VARIOS "TASKS".

GENERA UN PLAN FÍSICO Y UTILIZA EL CLUSTER MANAGER PARA COORDINAR QUE EXECUTORS VAN A AGENDAR Y EJECUTAR CUALES TASKS.

PROCESAMIENTO RDD




EL SCHEDULER UTILIZADO SE ENCUENTRA DENTRO DEL CLUSTER MANAGER, Y SE LLAMA DAG SCHEDULER.

LA SIGLA DAG VIENE DE GRÁFO DIRIGIDO ACÍCLICO.

LOS DISTINTOS TASKS DE SPARK SE VAN A EJECUTAR DE ESTA FORMA.


EL DAG SCHEDULER ASIGNA LOS TASKS A LOS "WORKER NODES".

PROCESAMIENTO RDD




LOS “WORKER NODES” SON LOS SERVIDORES QUE CONTIENEN A LOS EXECUTORS.

UNA VEZ FINALIZADO EL TASK, EL EXECUTOR DEVUELVE EL RESULTADO DE SU TAREA AL DRIVER, EL CUÁL JUNTA TODOS LOS RESULTADOS PARA EL OUTPUT DEL PROGRAMA DE SPARK.



DRIVERS



ES EL LUGAR DONDE SE CREA SPARKCONTEXT.

ES EL PUNTO DE ENTRADA PARA EL SHELL INTERACTIVO, QUE ESTÁ DISPONIBLE SOLO PARA SCALA, PYTHON Y R.

EJECUTA LA FUNCIÓN PRINCIPAL (MAIN) DE LA APLICACIÓN.

ES RESPONSABLE DE PROGRAMAR TRABAJOS Y ASIGNAR RECURSOS PARA EJECUTAR TAREAS.

ES RESPONSABLE DE CONVERTIR LAS APLICACIONES DE USUARIO EN UNIDADES DE EJECUCIÓN MÁS PEQUEÑAS CONOCIDAS COMO TAREAS (TASK).

SPARK SESSION



CUANDO REALMENTE COMENCEMOS A ESCRIBIR NUESTRA APLICACIÓN SPARK, NECESITAREMOS UNA FORMA DE ENVIAR COMANDOS Y DATOS.

LO HACEMOS CREANDO PRIMERO UNA SPARKSESSION.

PARA ACCEDER A LA CONSOLA DE SCALA E INICIAR UNA SESIÓN INTERACTIVA, EJECUTAMOS SPARK-SHELL Y PARA INICIAR LA CONSOLA DE PYTHON EJECUTAMOS PYSARK.

ESTO INICIA UNA APLICACIÓN SPARK INTERACTIVA.

SPARK SESSION



TAMBIÉN EXISTE UN PROCESO PARA ENVIAR APLICACIONES INDEPENDIENTES A SPARK LLAMADO SPARK-SUBMIT, MEDIANTE EL CUAL PUEDE ENVIAR UNA APLICACIÓN PRECOMPILADA A SPARK. CUANDO INICIAMOS SPARK EN ESTE MODO INTERACTIVO, IMPLÍCITAMENTE CREAMOS UNA SPARKSESSION QUE ADMINISTRA LA APLICACIÓN SPARK.

CUANDO INICIAMOS A TRAVÉS DE UN SUBMIT DE TRABAJO, DEBEMOS CREARLO O ACCEDER A SPARKSESSION.

SPARK SESSION




LA INSTANCIA DE SPARKSESSION ES LA FORMA EN QUE SPARK EJECUTA COMANDOS DEFINIDOS POR EL USUARIO EN TODO EL CLÚSTER.

EXISTE UNA CORRESPONDENCIA UNO A UNO ENTRE UNA SPARKSESSION Y UNA APLICACIÓN SPARK.

EN SCALA Y PYTHON, LA VARIABLE ESTÁ DISPONIBLE COMO SPARK CUANDO INICIA LA CONSOLA.

EXECUTORS




SON RESPONSABLES DE EJECUTAR TAREAS Y REALIZAR EL PROCESAMIENTO DE DATOS.

LEEN Y ESCRIBEN EN FUENTES EXTERNAS.

ALMACENAN RESULTADOS INTERMEDIOS EN MEMORIA.


CLUSTER MANAGER



ES UN SERVICIO EXTERNO.

ES RESPONSABLE DE ADQUIRIR RECURSOS COMO CPU, MEMORIA Y MÁS PARA ASIGNARLOS A APLICACIONES DE SPARK.

TIPOS DE CLUSTER MANAGER




STANDALONE:

UN ADMINISTRADOR DE CLÚSTER SIMPLE INCLUIDO CON SPARK QUE FACILITA LA CONFIGURACIÓN DE UN CLÚSTER.

APACHE MESOS:

UN ADMINISTRADOR GENERAL DE CLÚSTERES QUE TAMBIÉN PUEDE EJECUTAR HADOOP MAPREDUCE Y APLICACIONES DE SERVICIO. (OBSOLETO ACTUALMENTE)

TIPOS DE CLUSTER MANAGER




HADOOP YARN:

EL ADMINISTRADOR DE RECURSOS EN HADOOP 2 Y 3.

KUBERNETES:

UN SISTEMA DE CÓDIGO ABIERTO PARA AUTOMATIZAR LA IMPLEMENTACIÓN, EL ESCALADO Y LA GESTIÓN DE APLICACIONES EN CONTENEDORES.

MODOS DE EJECUCIÓN




UN MODO DE EJECUCIÓN DA EL PODER DE DETERMINAR DÓNDE SE ENCUENTRAN FÍSICAMENTE LOS RECURSOS CUANDO SE EJECUTA UNA APLICACIÓN.

EXISTEN TRES MODOS PARA ELEGIR:

- MODO CLÚSTER
- MODO CLIENTE
- MODO LOCAL

MODOS DE EJECUCIÓN: CLUSTER




EL MODO CLUSTER ES PROBABLEMENTE LA FORMA MÁS COMÚN DE EJECUTAR APLICACIONES SPARK.

EN ESTE MODO, UN USUARIO ENVÍA UN JAR PRECOMPILADO, UNA SECUENCIA DE COMANDOS DE PYTHON O UNA SECUENCIA DE COMANDOS R A UN ADMINISTRADOR DE CLÚSTERES.

LUEGO, EL ADMINISTRADOR DEL CLUSTER INICIA EL PROCESO DEL DRIVER EN UN NODO WORKER DENTRO DEL CLUSTER, ADEMÁS DE LOS PROCESOS EJECUTORES.

ESTO SIGNIFICA QUE EL ADMINISTRADOR DEL CLUSTER ES RESPONSABLE DE MANTENER TODOS LOS PROCESOS RELACIONADOS CON LA APLICACIÓN SPARK.

MODOS DE EJECUCIÓN: CLIENTE




EL MODO DE CLIENTE ES CASI IGUAL QUE EL MODO CLUSTER, EXCEPTO QUE EL DRIVER SPARK PERMANECE EN LA MÁQUINA CLIENTE QUE ENVIÓ LA APLICACIÓN.

ESTO SIGNIFICA QUE LA MÁQUINA CLIENTE ES RESPONSABLE DE MANTENER EL PROCESO DEL DRIVER SPARK Y EL ADMINISTRADOR DEL CLUSTER MANTIENE LOS PROCESOS EJECUTORES.

ESTAS MÁQUINAS SE CONOCEN COMÚNMENTE COMO MÁQUINAS GATEWAY O NODOS EDGES.

MODOS DE EJECUCIÓN: LOCAL



EL MODO LOCAL ES UNA DESVIACIÓN SIGNIFICATIVA DE LOS DOS MODOS ANTERIORES.


EJECUTA TODA LA APLICACIÓN SPARK EN UNA SOLA MÁQUINA.

LOGRA EL PARALELISMO A TRAVÉS DE SUBPROCESOS EN ESA ÚNICA MÁQUINA.

ESTA ES UNA FORMA COMÚN DE APRENDER SPARK, PROBAR SUS APLICACIONES O EXPERIMENTAR ITERATIVAMENTE CON EL DESARROLLO LOCAL.

SIN EMBARGO, NO ES RECOMENDABLE USAR EL MODO LOCAL PARA EJECUTAR APLICACIONES DE PRODUCCIÓN.

PROCESAMIENTO SPARK



SPARK PUEDE CORRER ARRIBA DE VARIOS ADMINISTRADORES DE RECURSOS.


POR EJEMPLO SOBRE YARN DE HADOOP, APACHE MESOS, KUBERNETES, O DOCKER SWARM.

EN CASO DE ESTAR TRABAJANDO EN LA NUBE SE PUEDE UTILIZAR UNA VERSIÓN YA GESTIONADA POR LA NUBE.

PARA AWS TENEMOS EMR, PARA AZURE TENEMOS HDINSIGHTS, Y GOOGLE DATAPROC EN GCP.

TAMBIÉN CONTAMOS CON DATABRICKS, EMPRESA DE LOS CREADORES DE SPARK QUE ES OFRECIDO COMO SERVICIO CLOUD EN TODAS LAS NUBES.

INTERACCIÓN CON SPARK



LOS RDD SIGUEN SIENDO LA PIEZA FUNDAMENTAL DE SPARK, PERO SALVO DESARROLLOS DE SPARK EN VERSIONES VIEJAS, YA NO SON UTILIZADOS.

EXISTEN ABSTRACCIONES DE MÁS ALTO NIVEL COMO LOS DATAFRAMES DE SPARK QUE SON MÁS AMIGABLES CON EL USUARIO EN CUANTO A SU USO.

ADEMÁS, EXISTEN MODULOS DE LIBRERÍAS PARA FACILITAR EL USO DE SPARK A LOS USUARIOS.

Streaming

MLlib
For Machine Learning

GraphX
For Graph Computing

**Spark SQL &
DataFrames**

Spark Core API

R

Python

Scala

SQL

Java



DATA FRAMES



UN DATAFRAME ES LA API ESTRUCTURADA MÁS COMÚN Y SIMPLEMENTE REPRESENTA UNA TABLA DE DATOS CON FILAS Y COLUMNAS.

LA LISTA DE COLUMNAS Y LOS TIPOS EN ESAS COLUMNAS ES EL SCHEMA.

UNA ANALOGÍA SIMPLE SERÍA UNA HOJA DE CÁLCULO CON COLUMNAS CON NOMBRE.

LA DIFERENCIA FUNDAMENTAL ES QUE MIENTRAS UNA HOJA DE CÁLCULO SE ENCUENTRA EN UNA COMPUTADORA EN UNA UBICACIÓN ESPECÍFICA, UN SPARK DATAFRAME PUEDE ABARCAR CIENTOS DE COMPUTADORAS.

DATA FRAMES: PARTICIONES



PARA PERMITIR QUE CADA EJECUTOR REALICE EL TRABAJO EN PARALELO, SPARK DIVIDE LOS DATOS EN FRAGMENTOS, LLAMADOS PARTICIONES.

UNA PARTICIÓN ES UNA COLECCIÓN DE FILAS QUE SE ENCUENTRAN EN UNA MÁQUINA FÍSICA EN NUESTRO CLUSTER.

LAS PARTICIONES DE UN DATAFRAME REPRESENTAN CÓMO LOS DATOS SE DISTRIBUYEN FÍSICAMENTE EN SU GRUPO DE MÁQUINAS DURANTE LA EJECUCIÓN.

DATA FRAMES: PARTICIONES



ALGO IMPORTANTE A TENER EN CUENTA ES QUE CON DATAFRAMES, NO MANIPULAMOS LAS PARTICIONES INDIVIDUALMENTE.

SIMPLEMENTE ESPECIFICAMOS TRANSFORMACIONES DE DATOS DE ALTO NIVEL EN LAS PARTICIONES FÍSICAS Y SPARK DETERMINA CÓMO SE EJECUTARÁ REALMENTE ESTE TRABAJO EN EL CLÚSTER.

TRANSFORMACIONES



EN SPARK, LAS ESTRUCTURAS DE DATOS CENTRALES SON INMUTABLES, LO QUE SIGNIFICA QUE NO SE PUEDEN CAMBIAR UNA VEZ CREADAS.

ESTO PUEDE PARECER UN CONCEPTO EXTRAÑO AL PRINCIPIO, SI NO PUEDE CAMBIARLO, ¿CÓMO SE SUPONE QUE DEBE USARSE? PARA CAMBIAR UN DATAFRAME, SE DEBERÁ INDICARLE A SPARK CÓMO NOS GUSTARÍA MODIFICAR EL DATAFRAME QUE SE TIENE EN EL QUE SE DESEA.

ESTAS INSTRUCCIONES SE LLAMAN TRANSFORMACIONES.

TRANSFORMACIONES



LAS TRANSFORMACIONES NO DEVUELVEN NINGÚN RESULTADO.

ESTO SE DEBE A QUE ESPECIFICAMOS SOLO UNA TRANSFORMACIÓN ABSTRACTA, Y SPARK NO ACTUARÁ SOBRE LAS TRANSFORMACIONES HASTA QUE LLAMEMOS UNA ACCIÓN.

HAY DOS TIPOS DE TRANSFORMACIONES, LAS QUE ESPECIFICAN DEPENDENCIAS ESTRECHAS (NARROW DEPENDENCIES) Y LAS QUE ESPECIFICAN DEPENDENCIAS AMPLIAS (WIDE DEPENDENCIES).

TRANSFORMACIONES: NARROW



NARROW TRANSFORMATION: CONSISTEN EN DEPENDENCIAS EN LAS QUE CADA PARTICIÓN DE ENTRADA CONTRIBUIRÁ A UNA ÚNICA PARTICIÓN DE SALIDA.

ALGUNOS EJEMPLOS SON LAS FUNCIONES `FILTER()`, `SAMPLE()`, `MAP()` O `FLATMAP()`.

TRANSFORMACIONES: WIDE



WIDE TRANSFORMATION: SE UTILIZA CUANDO LA LÓGICA DE LA APLICACIÓN NECESITA DATOS QUE SE ENCUENTRAN EN DIFERENTES PARTICIONES Y ES NECESARIO MEZCLAR DICHAS PARTICIONES PARA AGRUPAR LOS DATOS NECESARIOS EN UN DATAFRAME DETERMINADO.

EJEMPLOS DE FUNCIONES: GROUPBYKEY() O REDUCEBYKEY().

LAZY EVALUATION



LAZY EVALUATION (EVALUACIÓN PEREZOSA) SIGNIFICA QUE SPARK ESPERARÁ HASTA EL ÚLTIMO MOMENTO PARA EJECUTAR EL GRÁFICO DE INSTRUCCIONES DE CÁLCULO.

EN SPARK, EN LUGAR DE MODIFICAR LOS DATOS INMEDIATAMENTE CUANDO EXPRESAMOS ALGUNA OPERACIÓN, CONSTRUIMOS UN PLAN DE TRANSFORMACIONES QUE SE APLICARÁN A NUESTROS DATOS DE ORIGEN.

ESTO BRINDA INMENSOS BENEFICIOS PARA EL USUARIO FINAL PORQUE SPARK PUEDE OPTIMIZAR TODO EL FLUJO DE DATOS DE PRINCIPIO A FIN.

LAZY EVALUATION



SI CONSTRUIMOS UN GRAN TRABAJO DE SPARK, PERO ESPECIFICAMOS UN FILTRO AL FINAL QUE SOLO REQUIERE QUE OBTENGAMOS UNA FILA DE NUESTROS DATOS DE ORIGEN, LA FORMA MÁS EFICIENTE DE EJECUTAR ESTO ES ACCEDER AL ÚNICO REGISTRO QUE NECESITAMOS.

SPARK REALMENTE OPTIMIZARÁ ESTO, EMPUJANDO EL FILTRO HACIA EL PRINCIPIO AUTOMÁTICAMENTE.

ACCIONES



LAS TRANSFORMACIONES NOS PERMITEN CONSTRUIR NUESTRO PLAN LÓGICO DE TRANSFORMACIÓN.

PARA ACTIVAR EL CÁLCULO, EJECUTAMOS UNA ACCIÓN.

UNA ACCIÓN LE INDICA A SPARK QUE CALCULE UN RESULTADO DE UNA SERIE DE TRANSFORMACIONES.

LA ACCIÓN MÁS SIMPLE ES CONTAR, QUE NOS DA EL NÚMERO TOTAL DE REGISTROS EN EL DATAFRAME.

ACCIONES



HAY TRES TIPOS DE ACCIONES:

- ACCIONES PARA VER DATOS EN LA CONSOLA.
- ACCIONES PARA RECOPIRAR DATOS A OBJETOS NATIVOS EN EL LENGUAJE USADO.
- ACCIONES PARA ESCRIBIR DATOS DE SALIDA.

SPARK UI



DURANTE LA EJECUCIÓN DE SPARK, LOS USUARIOS PUEDEN MONITOREAR EL PROGRESO DE SU TRABAJO A TRAVÉS DE LA INTERFAZ DE USUARIO DE SPARK.

LA INTERFAZ DE USUARIO DE SPARK ESTÁ DISPONIBLE EN EL PUERTO 4040 DEL NODO DRIVER.

SI ESTÁ EJECUTANDO EN MODO LOCAL, SÓLO SERÁ EL `HTTP://LOCALHOST:4040`.

LA INTERFAZ DE USUARIO DE SPARK MANTIENE INFORMACIÓN SOBRE EL ESTADO DE LOS TRABAJOS, EL ENTORNO Y EL ESTADO DEL CLUSTER DE SPARK.

ES MUY ÚTIL, ESPECIALMENTE PARA AJUSTAR Y DEPURAR.

DESVENTAJAS DE SPARK




LA GRAN DESVENTAJA DE SPARK ES LA GRAN CANTIDAD DE MEMORIA RAM QUE REQUIERE PARA TRABAJAR.

ES IMPORTANTE CUIDAR LOS RECURSOS QUE UTILIZA UN PROCESO DE SPARK Y VERIFICAR SI NO PUEDE PROGRAMARSE DE MEJOR FORMA CUANDO UN PROCESO CONSUME UNA GRAN CANTIDAD DE ELLOS.

ESTO PODRÍA PERJUDICAR QUE CORRAN OTROS PROCESOS EN EL DATALAKE SI ESTAMOS ON PREMISE, Y HACERNOS INCURRIR EN MAYORES COSTOS SI ESTAMOS EN LA NUBE.

POSIBLES PREGUNTAS DE PARCIAL

- ¿Qué es Apache Spark y cuál fue su motivación principal de creación frente a Hadoop MapReduce?
- ¿Qué es un RDD y cuáles son sus características clave en el modelo de procesamiento de Spark?
- Explicar la diferencia entre transformaciones narrow y wide en Spark. Dar un ejemplo de cada una.
- ¿Cuál es la función de los componentes: Driver, Executor y Cluster Manager dentro de una aplicación Spark?
- ¿Qué es una SparkSession y cuál es su rol dentro de una aplicación Spark?
- ¿Qué modos de ejecución existen en Spark y en qué situaciones es recomendable usar cada uno?
- ¿Qué beneficios aporta el enfoque de lazy evaluation en Spark?
- Comparar Spark con Hadoop MapReduce en términos de rendimiento, facilidad de uso y flexibilidad.
- ¿Qué es un DataFrame en Spark y cómo se relaciona con el concepto de particiones en el clúster?
- ¿Cuál es la principal desventaja de Spark mencionada en la presentación y por qué puede representar un problema en entornos de producción?



GRACIAS

¿ALGÚN PUNTO QUE
QUIERAN REPASAR O
PROFUNDIZAR?