



HERRAMIENTAS DE SOFTWARE PARA BIG DATA

MODELADO DE DATOS - 10

¿DÓNDE ESTAMOS?



HASTA AHORA INGESTAMOS DATOS DE DISTINTAS FUENTES AL DATALAKE.

TANTO DATOS ESTRUCTURADOS COMO NO ESTRUCTURADOS. LOS DATOS ESTRUCTURADOS, POR EJEMPLO, LOS QUE PROVIENEN DE BASES DE DATOS, TRATAMOS CADA TABLA COMO UN ARCHIVO.

LUEGO DE LA INGESTA HACEMOS CON SPARK LAS TRANSFORMACIONES NECESARIAS PARA PODER TENER UNA VERSIÓN REFINADA DE ESOS ARCHIVOS.

¿A DÓNDE VAMOS?



NECESITAMOS ELEGIR PARA ESTOS ARCHIVOS UNA FORMA PARA PODER CONSUMIRLOS.

ARMAR UN MODELO PARA GUARDAR LOS DATOS QUE NOS PERMITA CONSULTARLOS.

ESTE MODELO DEBE SER ADECUADO PARA LOS DATOS QUE TENEMOS Y PARA LAS NECESIDADES DE NUESTRA ORGANIZACIÓN.

PARA ESTO PODEMOS USAR LOS ARCHIVOS ACTUALES O PODEMOS GENERAR NUEVOS ARCHIVOS, DEPENDIENDO DEL MODELO QUE VAYAMOS A ELEGIR.

¿POR QUÉ ES IMPORTANTE MODELAR LOS DATOS?



PORQUE AYUDA A ORGANIZAR Y ESTRUCTURAR LOS DATOS ALMACENADOS PARA QUE SEAN MÁS FÁCILES DE ENTENDER, ANALIZAR Y UTILIZAR.

UN DATALAKE ES UN REPOSITORIO CENTRALIZADO DE DATOS, QUE PUEDE CONTENER UNA GRAN CANTIDAD DE INFORMACIÓN EN DIFERENTES FORMATOS Y DE DIFERENTES ORÍGENES.

LA VARIEDAD Y CANTIDAD DE DATOS ALMACENADOS EN UN DATALAKE PUEDE SER ABRUMADORA, LO QUE HACE QUE SEA DIFÍCIL PARA LOS USUARIOS ENCONTRAR LOS DATOS QUE NECESITAN Y COMPRENDER SU SIGNIFICADO.

¿POR QUÉ ES IMPORTANTE MODELAR LOS DATOS?



EL MODELADO DE DATOS RESUELVE ESTE PROBLEMA AL DEFINIR UNA ESTRUCTURA LÓGICA Y COHERENTE PARA LOS DATOS ALMACENADOS EN EL DATALAKE.

AL CREAR UN MODELO DE DATOS, LOS DATOS SE ORGANIZAN EN TABLAS, LO QUE HACE QUE SEA MÁS FÁCIL PARA LOS USUARIOS BUSCAR, ENTENDER Y UTILIZAR LOS DATOS.

¿POR QUÉ ES IMPORTANTE MODELAR LOS DATOS?



ADEMÁS, EL MODELADO DE DATOS TAMBIÉN AYUDA A GARANTIZAR LA CALIDAD Y CONSISTENCIA DE LOS DATOS ALMACENADOS EN EL DATALAKE.

AL DEFINIR REGLAS Y RESTRICCIONES DE INTEGRIDAD DE DATOS, SE PUEDEN EVITAR ERRORES Y DUPLICACIONES EN LOS DATOS ALMACENADOS.

POR LO TANTO, EL MODELADO DE DATOS ES IMPORTANTE DENTRO DE UN DATALAKE PORQUE AYUDA A ORGANIZAR, ESTRUCTURAR Y COMPRENDER LOS DATOS ALMACENADOS, LO QUE A SU VEZ FACILITA SU USO Y MEJORA SU CALIDAD Y CONSISTENCIA.

¿CÓMO MODELAMOS LOS DATOS?




DE LAS TÉCNICAS QUE VAMOS A MENCIONAR, SON LAS REGLAS DEL NEGOCIO LAS QUE EN ÚLTIMA INSTANCIA VAN A DEFINIR CUÁL VAMOS A UTILIZAR.

PODEMOS USAR UNA, TODAS O ALGÚN HÍBRIDO.

LO IMPORTANTE ES TENER CLARO CUALES SON LAS NECESIDADES DE LA ORGANIZACIÓN, Y COMO LOS DATOS AYUDAN A QUE ESTAS SE CUMPLAN.

MODELO NORMALIZADO



ESTE MODELO PROPUESTO POR BILL INMON, EL PADRE DEL DATAWAREHOUSE TRATA DE REPLICAR LA FUENTE DE DATOS ORIGINAL DENTRO DEL DATALAKE, MANTENIENDO LA NORMALIZACIÓN DE LOS DATOS. A PARTIR DE LA RÉPLICA DE LAS FUENTES DE DATOS, SE CONSTRUYEN DATAMARTS QUE SON LUEGO CONSULTADOS POR LA CAPA ANALÍTICA.

DATAMART



UN DATAMART ES UNA SUBSECCIÓN DE UN DATA WAREHOUSE QUE SE ENFOCA EN UN ÁREA ESPECÍFICA DE UNA ORGANIZACIÓN, COMO LAS VENTAS, EL MARKETING O LAS FINANZAS.

TAMBIÉN PUEDE ENFOCARSE EN UNA FUNCIÓN DENTRO DE LA ORGANIZACIÓN.

SE UTILIZA PARA ALMACENAR DATOS QUE SE HAN EXTRAÍDOS, TRANSFORMADOS Y CARGADOS (ETL) DE DIFERENTES FUENTES, Y SE ORGANIZARON DE TAL MANERA QUE LOS USUARIOS PUEDEN ACCEDER A ELLOS DE MANERA FÁCIL Y RÁPIDA.

DATAMART




LOS DATAMARTS SUELEN ESTAR DISEÑADOS PARA SER UTILIZADOS POR UN GRUPO ESPECÍFICO DE USUARIOS, COMO EL EQUIPO DE VENTAS, EL EQUIPO DE MARKETING O EL EQUIPO DE FINANZAS.

ESTO SIGNIFICA QUE LOS DATOS SE PUEDEN PRESENTAR DE MANERA ESPECÍFICA PARA SATISFACER LAS NECESIDADES DE LOS USUARIOS, LO QUE AUMENTA LA EFICACIA DE LOS ANÁLISIS Y LOS INFORMES. SE PUEDEN UTILIZAR CON TODOS LOS MODELOS DE DATOS QUE VAMOS A REPASAR.

POR ESTO ROLES QUE NO SON NECESARIAMENTE TÉCNICOS EN INFORMÁTICA, PERO TIENEN FORMACIÓN ESPECÍFICA EN EL RUBRO DE LA EMPRESA, PUEDEN TRABAJAR COMO ANALISTAS DE DATOS.

MODELO NORMALIZADO




ALGUNAS VENTAJAS SON QUE LOS USUARIOS FUERA DEL DATALAKE YA CONOCEN EL MODELO DE DATOS DE LA FUENTE ORIGINAL Y AHORA LO TIENEN DISPONIBLE EN EL DATALAKE JUNTO A OTRAS FUENTES DE DATOS QUE LE PERMITEN ENRIQUECERLO.

SI PENSAMOS EN UN DATALAKE QUE TRABAJA COMO DATA MESH, CADA EQUIPO GESTIONA SUS PROPIOS DATOS Y LOS DISPONIBILIZA EN EL DATALAKE PARA EL RESTO DE LA EMPRESA:

LOS DATOS SON UNA ÚNICA FUENTE DE VERDAD, YA QUE ESTÁN IGUAL QUE LA FUENTE ORIGINA.

LA REDUNDANCIA ES BAJA PORQUE SE MANTIENE LA NORMALIZACIÓN.


MODELO NORMALIZADO



ENTRE SUS DESVENTAJAS SE ENCUENTRA QUE ES DIFÍCIL LLEGAR A HACER CONSULTAS SIN TENER QUE REALIZAR UNA GRAN CANTIDAD DE JOINS.

Y DIFÍCIL DE MANEJAR PARA QUIEN NO CONOCE LAS FUENTES ORIGINALES DE DATOS.


MODELO NORMALIZADO



POR MÁS QUE MANTENGAMOS LA NORMALIZACIÓN DE LOS DATOS. EL DATALAKE NO ES UNA BASE DE DATOS TRANSACCIONAL.


TIENE FINES ANALÍTICOS. NO CUMPLE CON LAS PROPIEDADES ACID, QUE SON UNA SERIE DE CARACTERÍSTICAS DE LAS TRANSACCIONES EN BASES DE DATOS RELACIONALES TRADICIONALES.

ACID



ACID SIGNIFICA ATOMICIDAD, CONSISTENCIA, AISLAMIENTO Y DURABILIDAD, Y ESTAS PROPIEDADES GARANTIZAN QUE LAS TRANSACCIONES SEAN CONFIABLES Y SE COMPLETEN CORRECTAMENTE, INCLUSO EN PRESENCIA DE FALLAS O CONFLICTOS.


ACID



ATOMICIDAD (ATOMICITY): ESTO SIGNIFICA QUE UNA TRANSACCIÓN SE CONSIDERA UNA OPERACIÓN ÚNICA E INDIVISIBLE.

EN OTRAS PALABRAS, UNA TRANSACCIÓN SE EJECUTA POR COMPLETO O NO SE EJECUTA EN ABSOLUTO. SI UNA PARTE DE LA TRANSACCIÓN FALLA, TODAS LAS OPERACIONES REALIZADAS HASTA ESE PUNTO SE DESHACEN (SE REVIERTEN) PARA MANTENER LA CONSISTENCIA DE LOS DATOS.


ACID



CONSISTENCIA (CONSISTENCY): LA CONSISTENCIA GARANTIZA QUE UNA TRANSACCIÓN LLEVE LA BASE DE DATOS DESDE UN ESTADO VÁLIDO A OTRO ESTADO VÁLIDO.

EN OTRAS PALABRAS, LAS TRANSACCIONES DEBEN MANTENER LA INTEGRIDAD DE LA BASE DE DATOS Y CUMPLIR CON TODAS LAS RESTRICCIONES Y REGLAS DE NEGOCIO. SI UNA TRANSACCIÓN VIOLA ALGUNA REGLA DE CONSISTENCIA, SE RECHAZA.


ACID



AISLAMIENTO (ISOLATION): LA PROPIEDAD DE AISLAMIENTO ASEGURA QUE LAS TRANSACCIONES EN EJECUCIÓN SEAN INVISIBLES ENTRE SÍ HASTA QUE SE COMPLETEN.

ESTO EVITA QUE LAS TRANSACCIONES INTERFIERAN ENTRE SÍ Y GARANTIZA QUE CADA TRANSACCIÓN VEA UNA VERSIÓN COHERENTE DE LA BASE DE DATOS, COMO SI FUERA LA ÚNICA TRANSACCIÓN EN EJECUCIÓN.


ACID



DURABILIDAD (DURABILITY): LA DURABILIDAD SE REFIERE A LA CAPACIDAD DE LA BASE DE DATOS PARA MANTENER LOS EFECTOS DE UNA TRANSACCIÓN UNA VEZ QUE ESTA SE HA COMPLETADO CON ÉXITO.

INCLUSO EN CASO DE FALLAS EN EL SISTEMA, APAGONES DE ENERGÍA U OTROS PROBLEMAS, LOS CAMBIOS REALIZADOS POR UNA TRANSACCIÓN EXITOSA DEBEN PERSISTIR Y NO PERDERSE.

CONSISTENCIA EVENTUAL




EN LUGAR DE UTILIZAR TRANSACCIONES ACID, LOS DATALAKES UTILIZAN MODELOS DE CONSISTENCIA EVENTUAL

O TRANSACCIONES DE BAJA COHESIÓN PARA MANEJAR LOS DATOS.

REPASAR TEOREMA CAP.


CONSISTENCIA EVENTUAL



LA CONSISTENCIA EVENTUAL SIGNIFICA QUE LOS DATOS PUEDEN TARDAR UN TIEMPO EN PROPAGARSE A TRAVÉS DEL SISTEMA Y NO HAY GARANTÍA DE QUE LOS USUARIOS VERÁN LOS MISMOS DATOS EN EL MISMO MOMENTO.

LAS TRANSACCIONES DE BAJA COHESIÓN PERMITEN QUE LAS OPERACIONES DE ESCRITURA Y LECTURA SE REALICEN DE MANERA ASINCRÓNICA, LO QUE PUEDE GENERAR UNA MAYOR LATENCIA, PERO TAMBIÉN AUMENTA LA ESCALABILIDAD DEL SISTEMA.

MODELO DESNORMALIZADO




ESTE MODELO FUE DESARROLLADO POR RALPH KIMBALL.

LOS DATOS EXTRAÍDOS DE LA FUENTE DE DATOS, SON REFINADOS DE FORMA QUE CREAMOS NUEVAS TABLAS CON LOS MISMOS.

CREAMOS TABLAS DE HECHOS CON AGREGACIONES Y TABLAS DIMENSIONALES, LO QUE CONOCEMOS COMO DIAGRAMA ESTRELLA.

EL DIAGRAMA DE SNOWFLAKE (COPO DE NIEVE) ES UN DERIVADO DEL ESTRELLA, DONDE CADA DIMENSIÓN PUEDE TENER SUS PROPIAS DIMENSIONES.

MODELO DESNORMALIZADO




LAS TABLAS DE DIMENSIONES PUEDEN SER DE DOS TIPOS.

QUE CONSERVEN VALORES HISTÓRICOS, O QUE NO LOS CONSERVEN.

AL ARMAR UNA TABLA DE DIMENSIONES ASÍ NORMALMENTE UTILIZAMOS EL RANGO DE FECHA EN EL QUE EL REGISTRO SE MANTUVO EN UN ESTADO Y LA FECHA DE CAMBIO HASTA UNA FECHA INFINITA PARA EL NUEVO ESTADO.

PODEMOS TAMBIÉN USAR UN NÚMERO U OTRA REFERENCIA.

MODELO DESNORMALIZADO



COMO DESVENTAJA PODEMOS SEÑALAR QUE HAY REDUNDANCIA EN LOS DATOS Y ES MÁS COMPLEJO DE ARMAR Y MANTENER.

COMO VENTAJA PODEMOS MENCIONAR QUE ES MÁS FÁCIL CONSULTARLO, PORQUE SE NECESITAN MENOS JOINS PARA RESPONDER UNA PREGUNTA, ES MÁS RÁPIDO AL TENER CIERTAS AGREGACIONES YA PRECALCULADAS, Y, ES MÁS FÁCIL ARMAR UN DATAMART A PARTIR DE ESTE MODELO. POR LO TANTO, TAMBIÉN ES MÁS AMIGABLE CON TECNICOS NO INFORMÁTICOS QUE TIENEN ALTO CONOCIMIENTO DEL NEGOCIO.

DATA VAULT



FUE PROPUESTO POR DAN LINSTEDT.

ES UNA METODOLOGÍA DE MODELADO DE DATOS QUE SE ENFOCA EN LA ESCALABILIDAD, LA FLEXIBILIDAD Y LA AGILIDAD EN LA GESTIÓN DE GRANDES VOLUMENES DE DATOS.

DATA VAULT



LOS DATOS SE ALMACENAN EN TABLAS BÁSICAS LLAMADAS "ENTIDADES" QUE CONTIENEN INFORMACIÓN SOBRE LOS OBJETOS DEL MUNDO REAL, COMO CLIENTES, PRODUCTOS O TRANSACCIONES.

LUEGO, SE CREAN TABLAS ADICIONALES LLAMADAS "RELACIONES" QUE SE UTILIZAN PARA VINCULAR LAS ENTIDADES Y ALMACENAR INFORMACIÓN SOBRE LAS RELACIONES ENTRE ELLAS.

DATA VAULT



LA ESTRUCTURA DEL DATA VAULT ESTÁ DISEÑADA PARA SER MODULAR Y ESCALABLE, LO QUE PERMITE LA INCORPORACIÓN DE NUEVAS ENTIDADES Y RELACIONES DE MANERA SENCILLA Y SIN AFECTAR LA ESTRUCTURA GENERAL DEL MODELO.

ADEMÁS, LA METODOLOGÍA DE DATA VAULT TAMBIÉN INCORPORA TÉCNICAS PARA ASEGURAR LA INTEGRIDAD Y LA CALIDAD DE LOS DATOS ALMACENADOS, ASÍ COMO LA CAPACIDAD DE RASTREAR EL ORIGEN Y EL HISTORIAL DE LOS DATOS.

DATA VAULT



UNA DE LAS PRINCIPALES VENTAJAS DEL ENFOQUE DE DATA VAULT ES SU CAPACIDAD PARA ADAPTARSE A LOS CAMBIOS EN LOS REQUISITOS DE DATOS DE LA ORGANIZACIÓN, LO QUE LO HACE ESPECIALMENTE ADECUADO PARA EMPRESAS CON DATOS COMPLEJOS Y EN CONSTANTE CAMBIO.

DATA VAULT



TAMBIÉN SE CONSIDERA UNA METODOLOGÍA DE ALMACÉN DE DATOS ÁGIL, LO QUE SIGNIFICA QUE SE ENFOCA EN LA ENTREGA RÁPIDA DE INFORMACIÓN DE ALTA CALIDAD A TRAVÉS DE ITERACIONES Y RETROALIMENTACIÓN CONTINUA.

DATA VAULT



ES EL MODELO MÁS COMPLEJO, MÁS DIFÍCIL DE IMPLEMENTAR Y MANTENER, Y QUE MAYOR CAPACIDAD DE ALMACENAMIENTO REQUIERE, HACIÉNDOLO UNO DE LOS MÁS COSTOSOS EN RECURSOS DE ESPACIO.

TAMBIÉN SE REQUIERE DE PERSONAL ALTAMENTE CAPACITADO PARA TRABAJAR CON ÉL.

ONE BIG TABLE



ES DE LOS MODELOS MÁS SIMPLES.

CONSISTE EN TOMAR TODOS LOS DATOS DE UN ORIGEN Y ARMAR CON ELLOS UNA GRAN TABLA, HACIENDO JOIN CON TODAS LAS TABLAS, PARA CONSTRUIR UNA SÁBANA DE DATOS.

ESTO DESNORMALIZA TOTALMENTE LA BASE DE DATOS, Y SE OBTIENE UNA ALTA REDUNDANCIA DE LOS MISMOS.

ONE BIG TABLE



ES MUY SIMPLE DE CONSTRUIR Y PERMITE REALIZAR DATAMARTS RÁPIDAMENTE CON UNOS POCOS JOINS.

EL EQUIPO PUEDE ENFOCARSE MUCHO MÁS EN LA LÓGICA DEL NEGOCIO Y DAR RESPUESTAS A LOS REQUERIMIENTOS ANALÍTICOS, QUE ENFOCARSE EN EL MANTENIMIENTO DE LOS MODELOS.


ONE BIG TABLE



LA GRAN DESVENTAJA ES QUE A PESAR DE QUE EL ALMACENAMIENTO DE TABLAS QUE SEAN MÁS AMPLIAS, CON VARIAS COLUMNAS ES BARATO Y LA CAPACIDAD PARA CONSULTARLAS EXISTE, A MEDIDA QUE AUMENTEN LOS DATOS EN CANTIDAD DE REGISTROS, SE HACE MÁS DIFÍCIL CONSULTARLOS, POR LO QUE A FUTURO ES UN MODELO QUE VA A TENER PROBLEMAS PARA ESCALAR SI AUMENTA MASIVAMENTE EL VOLUMEN DE DATOS. POR LO QUE TENEMOS QUE PENSAR EN MUCHOS REGISTROS, PERO CON POCAS COLUMNAS.

POSIBLES PREGUNTAS DE PARCIAL

- ¿Por qué es importante modelar los datos en proyectos de Big Data?
- ¿Qué características definen al modelo normalizado?
- ¿Cuáles son las ventajas o propósitos de utilizar un modelo desnormalizado?
- ¿Qué es un Datamart y cuál es su función?
- ¿Qué principios definen las propiedades ACID en el contexto del modelado de datos?
- ¿Qué significa "consistencia eventual" y en qué tipo de sistemas se aplica?
- ¿Cuáles son las características principales que tiene el modelo Data Vault?
- ¿Qué se entiende por "One Big Table" y en qué situaciones puede ser útil?
- ¿Cómo se diferencia un modelo normalizado de uno desnormalizado?
- ¿Qué factores se deben tener en cuenta al elegir un modelo de datos en un proyecto de Big Data?



GRACIAS

¿ALGÚN PUNTO QUE
QUIERAN REPASAR O
PROFUNDIZAR?