



HERRAMIENTAS DE SOFTWARE PARA BIG DATA

DATALAKE - 03

¿QUÉ ES BIG DATA?



“BIG DATA SON LOS DATOS QUE EXCEDEN LA CAPACIDAD DE PROCESAMIENTO DE LOS SISTEMAS DE BASES DE DATOS CONVENCIONALES. LOS DATOS SON DEMASIADO GRANDES, SE MUEVEN DEMASIADO RÁPIDO O NO SE AJUSTAN A LAS RESTRICCIONES DE LAS ARQUITECTURAS DE BASE DE DATOS. PARA OBTENER VALOR DE ESTOS DATOS, SE DEBE ELEGIR UNA FORMA ALTERNATIVA DE PROCESARLOS.”

EDD DUMBILL, O'REILLY

LAS 5 V QUE HACEN QUE LA DATA SEA BIG DATA



VALOR

LA INFORMACIÓN ES DE VALOR E INTERÉS DE LA ORGANIZACIÓN.

VOLUMEN

LA INFORMACIÓN ES DE UN GRAN VOLÚMEN, TAL QUE NO PUEDE SER GESTIONADA POR UN SISTEMA DE BASE DE DATOS CONVENCIONAL, NI TAMPOCO SER PROCESADA DE FORMA CONVENCIONAL.

VELOCIDAD

LOS DATOS SE GENERAN A DISTINTAS VELOCIDADES. ALGUNOS EN TIEMPO REAL, OTROS DE FORMA DIARIA, SEMANAL, MENSUAL O ANUAL.

LAS 5 V QUE HACEN QUE LA DATA SEA BIG DATA



VARIEDAD

LOS DATOS SON DE VARIADOS ORÍGENES, SOBRE DISTINTOS DOMINIOS DEL NEGOCIO, Y VIENEN EN VARIADOS FORMATOS. (CLAVE VALOR, JSON, TABULARES, XML, TEXTO, FOTOS, CSV, ETC.). SON ESTRUCTURADOS Y NO ESTRUCTURADOS.

VERACIDAD.

LOS DATOS DEBEN REPRESENTAR LA REALIDAD DE LA ORGANIZACIÓN. SE DEBE CUIDAR ANTES DE INGESTARLOS A REPOSITORIOS CENTRALIZADOS DE DATOS, AL PROCESARLOS, Y AL ENTREGARLOS QUE ESTOS SEAN VERACES.

¿CÓMO FUE CRECIENDO EL VOLUMEN DE DATOS?

Datos Dispersos

Las organizaciones tienen una o varias aplicaciones. Esas aplicaciones tienen uno o varios servicios que usan diversas bases de datos, con distintos paradigmas. (Relacionales, Documentos, Grafos)

Más Fuentes de Datos

Además, pueden contar con sensores (IoT), e información externa a la organización. Redes sociales que podemos scrapear, datos públicos que podemos tomar mediante apis u otros métodos.

Más Necesidades

Las organizaciones necesitan juntar y compilar esos grandes volúmenes de datos para poder disponer de ellos a tiempos y costos razonables, para poder sacar una ventaja competitiva.

¿CUÁL ES LA SOLUCIÓN?



EL DATALAKE.

UNA LAGUNA DE DATOS (DATALAKE) ES UN REPOSITORIO CENTRALIZADO (EN APARIENCIA PARA EL USUARIO) QUE PERMITE ALMACENAR TODOS LOS DATOS ESTRUCTURADOS Y NO ESTRUCTURADOS A CUALQUIER ESCALA.



¿CÓMO FUNCIONA UN DATALAKE?

COMPONENTES DEL DATALAKE




EL DATALAKE, COMO REPOSITORIO DE GRANDES VOLUMENES DE DATOS PASA A SER LA PARTE MÁS IMPORTANTE DE LA INFRAESTRUCTURA DE DATOS DENTRO DE LA ORGANIZACIÓN QUE LO IMPLEMENTA.

VAMOS A ANALIZAR LAS PARTES QUE TIENE UN DATALAKE Y COMO INTERACTUA CON EL RESTO.

PARA EMPEZAR, HAY TRES FORMAS DE IMPLEMENTAR UN DATALAKE:


- EN NUESTRAS PROPIAS INSTALACIONES (ON PREMISE)
- EN LA NUBE (SOLUCIONES CLOUD)
- UN FORMATO HÍBRIDO QUE COMBINA LAS DOS ANTERIORES.



COMPONENTES DE UN DATALAKE

POSIBLES PREGUNTAS DE PARCIAL

- ¿Qué es Big Data y cuáles son sus principales características según Edd Dumbill?
- ¿Cuáles son las cinco "V" que caracterizan a Big Data y qué representa cada una? De ejemplos prácticos
- ¿Por qué los sistemas de bases de datos convencionales no pueden manejar Big Data de manera eficiente?
- ¿Cómo ha evolucionado el volumen de datos en los últimos años y qué impacto tiene en la infraestructura tecnológica?
- ¿Qué es un DataLake y cuál es su propósito principal en una organización?
- ¿Cómo se diferencia un DataLake de un DataWarehouse?
- ¿Cuáles son los beneficios principales de implementar un DataLake en una empresa?
- ¿Por qué un DataLake es considerado una solución escalable para el almacenamiento de datos?
- ¿Qué tipo de datos pueden almacenarse en un DataLake?
- ¿Cuáles son las tres formas de implementar un DataLake y en qué se diferencian?
- ¿Qué ventajas ofrece un DataLake basado en la nube frente a una implementación on-premise?
- ¿Cuáles son los principales componentes de un DataLake y cuál es la función de cada uno?
- ¿Cómo se gestiona la ingesta de datos en un DataLake y qué consideraciones deben tomarse en cuenta?
- ¿Qué papel juega la veracidad de los datos en un DataLake y cómo se garantiza?
- ¿Cómo interactúa un DataLake con otras soluciones de análisis y procesamiento de datos dentro de una organización?
- ¿Cuáles son los principales desafíos en la gestión de un DataLake y cómo pueden abordarse?
- ¿Qué tipo de herramientas pueden utilizarse para la consulta y análisis de datos en un DataLake?
- ¿Cómo impacta la velocidad de generación de datos en la eficiencia de un DataLake?
- ¿Cómo se manejan los datos no estructurados dentro de un DataLake?
- ¿Por qué un DataLake se percibe como un repositorio centralizado para el usuario?



GRACIAS

¿ALGÚN PUNTO QUE
QUIERAN REPASAR O
PROFUNDIZAR?